Instituto Superior de Engenharia de Lisboa (ISEL)
Departamento de Engenharia Informática (DEI)

Licenciatura em Engenharia Informática e Multimédia (LEIM)
Unidade Curricular de Projeto (PRJ)

LGP-Eval



Rodrigo Neves (51452)

Diogo Santiago (51998)

Orientador(es)

Professor [Doutor] Pedro Mendes Jorge

Professor Tiago Gonçalves

Julho, 2026

Resumo

A Língua Gestual Portuguesa (LGP) é o principal meio de comunicação da comunidade Surda portuguesa, contudo, o acesso a ferramentas de aprendizagem autónoma permanece reduzido. As soluções tecnológicas existentes centram-se maioritariamente noutras línguas gestuais e, frequentemente, descuram a validação das propriedades espaciais intrínsecas à execução gestual. Este trabalho apresenta o LGP-Eval, um sistema web de avaliação e aprendizagem de gestos de LGP em tempo real. Em contraponto aos sistemas de reconhecimento convencionais que apenas informam se um gesto foi classificado com sucesso, o LGP-Eval tem como foco o fornecimento de retroação pedagógica contínua. O sistema identifica e comunica ao utilizador o elemento anatómico que requer ajuste — como a orientação do pulso ou a posição dos dedos — guiando-o ativamente durante a execução.

A extração das coordenadas articulares é assegurada pela biblioteca MediaPipe Holistic através de uma webcam comum, sem recurso a hardware especializado. A abordagem computacional desenvolvida integra a normalização espacial da geometria da mão, a contextualização locativa ancorada na pose do utilizador, e o alinhamento temporal de sequências multidimensionais com recurso ao algoritmo Dynamic Time Warping (DTW).

A interface sobrepõe guias visuais e alertas textuais na imagem da câmara. O sistema foi validado através de testes com utilizadores finais, com uma classificação média de 89,3 no System Usability Scale (SUS), um resultado considerado de excelência. O LGP-Eval afirma-se, assim, como uma plataforma acessível, altamente usável e de baixo custo para o apoio à prática autónoma da LGP.

Abstract

Portuguese Sign Language (LGP) is the primary means of communication for the Portuguese Deaf community; however, access to autonomous learning tools remains limited. Existing technological solutions focus mostly on other sign languages and frequently neglect the validation of spatial properties intrinsic to gesture execution. This work presents LGP-Eval, a real-time web-based evaluation system for LGP gestures. In contrast to conventional recognition systems that merely report whether a gesture was successfully classified, LGP-Eval focuses on providing continuous pedagogical feedback. The system identifies and communicates to the user the specific anatomical element requiring adjustment — such as wrist orientation or finger position — actively guiding them during execution.

The extraction of joint coordinates is performed by the MediaPipe Holistic library using a standard webcam, without requiring specialized hardware. The developed computational approach integrates the spatial normalization of hand geometry, locative contextualization anchored to the user's pose, and the temporal alignment of multidimensional sequences using the Dynamic Time Warping (DTW) algorithm. To delimit gesture execution without explicit manual interaction, a finite state machine was implemented for automatic segmentation.

The interface overlays visual guides and textual alerts directly onto the camera feed. The system was validated through end-user testing, achieving an average score of 89.3 on the System Usability Scale (SUS), a result considered to be of excellence. LGP-Eval thus establishes itself as an accessible, highly usable, and low-cost platform to support the autonomous practice of LGP.

Agradecimentos

Gostaríamos de expressar o nosso sincero agradecimento a todos os que contribuíram direta ou indiretamente para a concretização deste projeto e para a conclusão desta etapa académica.

Um agradecimento especial aos nossos orientadores, o Professor Doutor Pedro Mendes Jorge e o Professor Tiago Gonçalves, pela disponibilidade constante, rigor científico, partilha de conhecimento e orientação fundamental ao longo de todo o desenvolvimento do LGP-Eval.

Aos nossos colegas e amigos, pelo companheirismo, partilha de ideias e incentivo demonstrados ao longo de todo o percurso académico.

Por fim, um agradecimento profundo às nossas famílias, pelo apoio incondicional e confiança depositada em todos os momentos de maior exigência.

Às nossas famílias, pelo amor, exemplo e suporte inesgotável em todas as circunstâncias.

Aos nossos amigos, por caminharem a nosso lado e tornarem esta jornada inesquecível.

À persistência que nos trouxe até aqui.

Índice

Resumo **i**

Abstract **iii**

Agradecimentos **v**

Índice **ix**

Lista de Tabelas **xiii**

Lista de Figuras **xv**

1 Introdução **1**

1.1 Motivação 1
1.2 Objetivos 2
1.3 Contribuições Principais 3
1.4 Processo de Desenvolvimento e Validação 4
1.5 Estrutura do Documento 5
1.6 Utilização de Inteligência Artificial Generativa 6

2 Trabalho Relacionado **7**

2.1 Contexto e Paradigma de Avaliação 7
2.2 Reconhecimento de Gestos Estáticos 9
2.3 Segmentação Temporal e o Problema do *Movement Epenthesis* 10
2.4 *Dynamic Time Warping* e Pré-Processamento do Sinal Esquelético 11
2.5 Contextualização Espacial: da Mão ao Corpo 12
2.6 Reconhecimento em Ambiente Web sem Hardware Dedicado . 13

2.7 Síntese e Aspetos Diferenciadores 14

3 Modelo Proposto **15**
3.1 Requisitos 15
3.2 Fundamentos 16
3.2.1 Contextualização Espacial: Zonas Corporais Dinâmicas 17
3.2.2 Avaliação Dinâmica de Sequências Gestuais 18
3.3 Abordagem 19
3.3.1 Pipeline de Processamento 20
3.3.2 Normalização Geométrica: Justificação da Invariância à Distância 20

4 Implementação do Modelo **23**
4.1 Tecnologias e Dependências 23
4.2 Estrutura de Dados e Armazenamento 25
4.3 Gestão de Estados e Segmentação Automática 26
4.4 Implementação do Motor Estático 27
4.5 Implementação do Motor Dinâmico 29
4.6 Sincronização Visual e Feedback 34

5 Validação e Testes **37**
5.1 Metodologia e Perfil dos Utilizadores 37
5.2 Avaliação Prática e Qualitativa 38
5.3 Avaliação Quantitativa de Usabilidade (SUS) 39
5.4 Análise Crítica e Dificuldades 40

6 Conclusões e Trabalho Futuro **43**
6.1 Síntese e Conclusões 43
6.2 Trabalho Futuro 44

A Especificação de Requisitos e Casos de Utilização **45**
A.1 Requisitos Funcionais 45
A.2 Requisitos Não Funcionais 46
A.3 Modelo de Casos de Utilização 47
A.4 Matriz de Prioridades dos Casos de Utilização 48

B Excertos de Código-Fonte **51**

C Gestão de Versões e Controlo de Código **57**
C.1 Ramos e Junções (*Branches* e *Merges*) 57
C.2 Arquitetura de Sincronização 58

Bibliografia **59**

Lista de Tabelas

2.1 Comparação entre o LGP-Eval e outras plataformas/sistemas de ensino e tradução. 14

4.1 Exemplo reduzido da banda de Sakoe-Chiba ($N = 5$, $M = 7$, $w = 1$, banda $= \max(w, |N - M|) = 2$). 31

5.1 Indicadores qualitativos de desempenho e perceção prática por participante. 38
5.2 Perfil demográfico dos participantes e pontuação SUS individual. 39

A.1 Matriz de Prioridades dos Casos de Utilização. 49

Lista de Figuras

2.1 Matriz de custo DTW com restrição global da Banda de Sakoe-Chiba. A área sombreada delimita a janela de pesquisa de largura total $2w$, centrada na diagonal; o caminho a vermelho ilustra um alinhamento ótimo válido dentro da banda. 12

3.1 Arquitetura do *pipeline* de processamento do LGP-Eval, da captura de vídeo à decisão pedagógica. 19

4.1 Fluxo de processamento e dependências tecnológicas isoladas no ambiente do cliente. 25
4.2 Modelo esquelético da mão, com destaque para o osso da palma (pulso, ponto 0, à base do dedo médio, ponto 9), adotado como régua biométrica para a normalização de escala. . . 28
4.3 Máquina de estados híbrida para segmentação temporal autónoma de gestos dinâmicos. 30
4.4 Mapeamento vetorial das cinco distâncias relativas (`distRelFace`) utilizadas na avaliação de gestos dinâmicos. 33
4.5 Interface de treino do LGP-Eval, demonstrando a sobreposição de elementos no `Canvas`: esqueleto fantasma, zonas corporais delimitadas, bússola de inclinação, fotografia do gesto e barra de progresso. 35

Capítulo 1

Introdução

1.1 Motivação

O panorama tecnológico atual mostra um esforço crescente, a nível global e nacional, para incluir a comunidade surda através de ferramentas digitais. Em Portugal, a disponibilização da aplicação de emergência MAI112 para cidadãos surdos [Ministério da Administração Interna, 2026] evidencia este compromisso institucional. Contudo, esta solução ilustra um desafio comum: opera exclusivamente através de texto, não permitindo a comunicação direta na língua natural do utilizador.

No domínio da aprendizagem e tradução, o cenário de exclusão da Língua Gestual Portuguesa (LGP) mantém-se. Plataformas generalistas de ensino de línguas, como o Duolingo [Duolingo, Inc., 2026], dominam o mercado da aprendizagem autónoma mas não disponibilizam qualquer curso de língua gestual. Em paralelo, surgiram soluções dedicadas a línguas gestuais individuais: o Pocket Sign ASL [MobiReactor, 2026] disponibiliza um dicionário visual para a ASL, enquanto o HandTalk [Hand Talk, 2026] se afirma como tradutor automático de texto e voz para LIBRAS.

Estas iniciativas confirmam a viabilidade técnica para tecnologia de apoio à língua gestual, mas revelam duas limitações críticas. A primeira é de cobertura linguística, uma vez que nenhuma contempla a LGP. A segunda é de natureza funcional: o foco recai quase inteiramente sobre a tradução passiva. Do ponto de vista pedagógico, esta lacuna insere-se no problema mais geral estudado pela disciplina de Aprendizagem de Línguas Assistida por Computador (Computer-Assisted Language Learning - CALL), que situa o

computador ora como tutor, ora como ferramenta [Levy, 1997]. Esta literatura debruça-se historicamente sobre línguas orais; a transposição do modelo de tutor — capaz de avaliar e corrigir autonomamente a produção do aprendiz — para o domínio viso-gestual permanece subexplorada e, no caso da LGP, inexistente.

Para validar empiricamente o impacto desta lacuna e a necessidade de uma abordagem interativa, o presente estudo recolheu dados junto de um painel de utilizadores sem formação técnica ou linguística. A amostra revelou um distanciamento claro: a totalidade dos participantes declarou não possuir qualquer familiaridade prévia com a LGP, sendo que a esmagadora maioria nunca havia tentado aprender qualquer língua gestual. No entanto, ao serem expostos a um modelo de ensino corretivo, todos os utilizadores conseguiram executar um novo gesto de forma bem-sucedida. Este contraste demonstra que a principal barreira à aprendizagem autónoma não é a complexidade intrínseca da língua, mas sim a ausência de sistemas que atuem como verdadeiros tutores interativos com orientação postural em tempo real. Esta distinção de propósito é central ao projeto: um sistema de tradução avalia implicitamente se um gesto é reconhecível; um tutor precisa de avaliar explicitamente se o gesto está correto e de indicar como o melhorar. Foi desta constatação que nasceu o LGP-Eval: não um dicionário ou tradutor passivo, mas uma ferramenta pedagógica de treino guiado que capta a execução do utilizador e devolve correção imediata, aplicando à LGP um princípio de avaliação automática já validado na literatura para outras línguas gestuais (Capítulo 2).

1.2 Objetivos

O objetivo geral do presente trabalho é o desenvolvimento do LGP-Eval, uma ferramenta pedagógica de treino guiado que capta os movimentos do utilizador e fornece orientação corretiva sobre a execução de gestos da LGP. Para a concretização desta meta, definem-se objetivos específicos focados na viabilidade, interação e pedagogia.

Primeiramente, visa-se garantir a análise do movimento em tempo real, extraindo coordenadas articulares através de equipamentos de consumo corrente, como uma webcam padrão, eliminando assim a barreira de entrada

associada a sensores especializados. No domínio do reconhecimento, o sistema propõe-se a identificar e guiar o utilizador na execução de gestos da LGP — abrangendo tanto a sua componente estática como dinâmica — e a validar a exatidão locativa do movimento. Esta contextualização espacial é um objetivo central, garantindo que o sistema reconhece não apenas a forma da mão, mas também se o gesto é executado na zona anatómica correta, uma propriedade com valor fonológico na LGP.

Por fim, no plano da interação humano-computador, o objetivo estabelece-se na entrega de retroação pedagógica multimodal. Pretende-se que o sistema combine guias visuais e alertas textuais de forma imediata e clara, conduzindo o utilizador à auto-correção efetiva, premissa esta validada por testes empíricos de usabilidade. Para acomodar as diferentes fases de retenção de conhecimento, o projeto tem ainda como objetivo estruturar a experiência em dois eixos funcionais: um ambiente de aprendizagem guiada, com apoio visual intensivo para aquisição motora, e um modo de avaliação livre, focado na consolidação da fluência.

1.3 Contribuições Principais

O valor acrescentado deste trabalho, face às abordagens de tradução existentes, assenta em cinco contribuições técnicas principais, todas implementadas e executadas do lado do cliente (*frontend*), sem dependência de servidores de inferência:

- **Mecanismo de Correspondência Estática:** normalização espacial das coordenadas da mão e cálculo das relações geométricas entre os pontos articulares extraídos. Esta abordagem permite a correspondência e avaliação de posturas manuais face a um molde de referência, assegurando invariância relativamente à escala e à distância do utilizador à câmara.

- **Delimitação de Zonas Locativas:** definição em tempo real de quatro regiões anatómicas principais (Testa, Queixo, Peito e Abdómen). Este mecanismo contextualiza espacialmente a execução do gesto, auxiliando o utilizador a posicionar corretamente a mão na zona de articulação requerida pelo referencial.

- **Motor de Avaliação Temporal:** implementação de um sistema de alinhamento de sequências temporais baseado numa otimização do algoritmo *Dynamic Time Warping* (DTW). Esta adaptação permite comparar a execução de gestos dinâmicos com um referencial, gerindo eficazmente as variações naturais de velocidade e ritmo de execução entre diferentes utilizadores.

- **Segmentação Automática da Execução:** integração de uma máquina de estados finita que delimita as fronteiras do gesto de forma automática. Este mecanismo previne a fragmentação do movimento e elimina a necessidade de interação manual explícita do utilizador para iniciar ou concluir a avaliação.

- **Sistema de Retroação Pedagógica Multimodal:** desenvolvimento de uma interface que complementa a avaliação computacional com guias visuais em tempo real, incluindo um esqueleto fantasma, bússola de inclinação e delimitação das zonas corporais. O foco recai sobre a entrega de alertas imediatos dirigidos ao elemento com maior erro, guiando ativamente o processo de auto-correção.

1.4 Processo de Desenvolvimento e Validação

O desenvolvimento apoiou-se no MediaPipe Holistic [Lugaresi e et al., 2019] para a extração de pontos de articulação, concentrando o esforço no motor de avaliação e no modelo pedagógico. O sistema foi construído em três camadas sucessivas, cada uma validada antes de avançar para a seguinte: (i) o motor estático, ajustando os limiares de erro médio e máximo por ponto; (ii) a contextualização por zonas corporais, validada pela estabilidade das zonas perante diferentes posturas e distâncias; (iii) o motor dinâmico DTW, cuja validação decorreu em dois ciclos: a calibração dos parâmetros críticos ($w = 10$, $\theta = 0{,}25$ de limiar de aceitação, e peso de penalização de zona fixado em 1,20) e o ajuste do mecanismo de segmentação automática ($t_d = 400\,\text{ms}$ de janela de *debounce*, com um mínimo de 8 *frames* válidas por segmento e um *buffer* de 150 *frames*). A validação funcional recorreu a um painel de telemetria que expõe, para cada gesto de referência, o erro calculado e o motivo de rejeição, além de um processo de calibração inicial que garante

deteção fiável da mão antes de iniciar a avaliação.

1.5 Estrutura do Documento

O presente documento encontra-se estruturado em seis capítulos, complementados por apêndices, organizados da seguinte forma:

- **Capítulo 2 – Trabalho Relacionado:** Enquadra o LGP-Eval face à literatura existente e a trabalhos anteriores focados no reconhecimento e tradução de língua gestual.
- **Capítulo 3 – Modelo Proposto:** Apresenta os fundamentos teóricos e a abordagem concetual da solução. Define os modos de funcionamento, o modelo de casos de utilização e os requisitos (funcionais e não funcionais) que orientaram o desenvolvimento.
- **Capítulo 4 – Implementação do Modelo:** Descreve a concretização técnica da arquitetura proposta. Detalha as tecnologias empregues, a estrutura de dados da base de referências, a máquina de estados de segmentação, a implementação dos motores de reconhecimento e a respetiva camada de *feedback* visual.
- **Capítulo 5 – Validação e Testes:** Foca-se na validação externa da ferramenta enquanto artefacto pedagógico. Detalha o estudo empírico de usabilidade conduzido com utilizadores reais para aferir a eficácia e acessibilidade do sistema.
- **Capítulo 6 – Conclusões e Trabalho Futuro:** Sintetiza as conclusões retiradas do projeto, reflete sobre o cumprimento dos objetivos e aponta perspetivas para a evolução futura da plataforma.

1.6 Utilização de Inteligência Artificial Generativa

Na elaboração deste relatório foram utilizadas ferramentas de Inteligência Artificial Generativa (*Large Language Models*, LLMs) como apoio a tarefas de revisão textual, estruturação de ideias em LaTeX e refatorização de excertos de código. Esta utilização seguiu as normas da unidade curricular relativas ao uso de IA Generativa: todas as interações relevantes com estas ferramentas encontram-se documentadas no anexo `prompt_set.txt`, e o código de autoria integral do(s) autor(es) está devidamente assinalado com a etiqueta `#my_code`, permitindo distinguir claramente o contributo pessoal do apoio prestado pela IA.

Capítulo 2

Trabalho Relacionado

2.1 Contexto e Paradigma de Avaliação

A investigação recente no domínio do Reconhecimento Automático de Língua Gestual (SLR) tem sido amplamente impulsionada por arquiteturas complexas de Aprendizagem Profunda (*Deep Learning*). Modelos híbridos de última geração, que combinam Redes Neuronais Convolucionais (CNN) para extração espacial, mecanismos de Auto-Atenção (SA) e redes de Memória Longo-Curto Prazo (LSTM) para dependências temporais, demonstraram a capacidade de atingir níveis de precisão na ordem dos 98,7% na identificação de gestos [Baihan et al., 2024].

Contudo, a própria literatura reconhece as limitações práticas destas abordagens: os modelos de *Deep Learning* exigem volumes massivos de informação etiquetada e um elevado poder computacional para treino [Baihan et al., 2024]. Devido a estas elevadas exigências de processamento, a utilização de *Deep Learning* pode apresentar dificuldades severas quando implementada em cenários do mundo real [Baihan et al., 2024], especialmente em dispositivos de consumo sem hardware dedicado.

Mais criticamente para o contexto deste projeto, a aplicação de modelos puramente estatísticos ou neuronais a contextos de ensino interativo esbarra numa limitação arquitetural fundamental: operam sob um paradigma de *black box*. Quando uma execução gestual falha, o classificador global indica o erro, mas é incapaz de isolar a falha anatómica específica (ex: um ângulo incorreto no pulso ou a falta de extensão de um dedo), impossibilitando a geração da retroação corretiva exata que um ambiente pedagógico exige.

Esta dupla necessidade explicabilidade pedagógica e acessibilidade computacional em tempo real — determinou o afastamento de modelos probabilísticos opacos em favor de uma abordagem baseada em processamento geométrico explícito. Este capítulo foca-se, assim, na literatura científica e nas abordagens tecnológicas que fundamentam a arquitetura da aplicação desenvolvida.

A construção de um sistema de avaliação gestual pedagógico em tempo real levanta quatro desafios técnicos principais, os quais norteiam a revisão da literatura apresentada nas secções seguintes:

1. **Segmentação temporal:** delimitar automaticamente o início e o término de um gesto num fluxo de vídeo contínuo de forma fluida.

2. **Alinhamento de sequências:** comparar uma execução capturada em tempo real com referências pré-gravadas, gerindo variações naturais de velocidade e duração.

3. **Contextualização espacial:** validar o local de articulação do movimento em relação ao corpo do utilizador. Na Língua Gestual Portuguesa, a região anatómica onde o gesto é executado é um parâmetro estrutural obrigatório, pelo que avaliar a correção de uma execução exige verificar não apenas a forma da mão, mas também se esta se encontra no espaço corporal correto.

4. **Acessibilidade técnica:** extrair e processar coordenadas articulares com precisão recorrendo exclusivamente a equipamentos de consumo corrente, como uma *webcam* padrão, eliminando a dependência de servidores de inferência ou sensores especializados.

2.2 Reconhecimento de Gestos Estáticos

Na literatura de Reconhecimento Automático de Língua Gestual, a avaliação de gestos estáticos (posturas da mão sem componente temporal) é frequentemente abordada através de duas vias distintas: modelos baseados em aparência (*appearance-based*) e modelos baseados na estrutura ou esqueleto (*model-based*) [Cheok et al., 2019].

A maioria das abordagens tradicionais recorre à extração de características da imagem (como contornos ou texturas) acoplada a classificadores estatísticos, sendo as Máquinas de Vetores de Suporte (SVM) e as Redes Neuronais Artificiais (ANN) os métodos mais populares e com melhores resultados reportados para gestos estáticos [Cheok et al., 2019]. Contudo, como discutido na secção anterior, a opacidade destes modelos dificulta a sua aplicação pedagógica.

Em alternativa, as abordagens geométricas (inseridas no paradigma *model-based*) procuram extrair um modelo esquelético da mão, calculando matematicamente relações como distâncias euclidianas, defeitos de convexidade (*convexity defects*) e ângulos entre as articulações [Cheok et al., 2019]. Esta vertente heurística, embora exija uma extração de coordenadas articulares altamente precisa, apresenta a vantagem de ser invariante à escala e rotação, permitindo comparações determinísticas. Ao conhecer a posição exata de cada falange, torna-se possível não só classificar o gesto por correspondência geométrica, mas também quantificar o desvio de cada dedo face a um referencial ideal.

2.3 Segmentação Temporal e o Problema do *Movement Epenthesis*

Um dos desafios mais estudados na arquitetura de sistemas de reconhecimento contínuo de língua gestual (CSLR) é a identificação correta das fronteiras temporais dos gestos [Cheok et al., 2019]. Aloysius e Geetha [Aloysius e Geetha, 2020] identificam o *Movement Epenthesis* (ME) como um obstáculo central neste domínio: os segmentos de transição entre gestos não transportam informação linguística, mas têm uma duração temporal comparável aos próprios gestos. Adicionalmente, dado um vocabulário de N gestos, existem potencialmente $\mathcal{O}(N^2)$ tipos de ME, tornando inviável a sua modelação estatística explícita à escala.

Este problema é relevante para o LGP-Eval num contexto mais restrito: embora o sistema não se destine a traduzir frases contínuas, necessita de distinguir de forma robusta o gesto intencional face aos movimentos de transição que o precedem e sucedem.

Enquanto as abordagens tradicionais (como Modelos Ocultos de Markov e campos condicionais) resolvem este desafio através da modelação explícita do ME ou da utilização de modelos de limiar, o LGP-Eval adota uma heurística espacial mais leve, desenhada para a execução em tempo real no navegador. Em vez de modelar as transições estatisticamente, o sistema define uma zona de repouso corporal e implementa uma máquina de estados finita. Este mecanismo monitoriza as entradas e saídas da mão face a essa zona âncora, permitindo delimitar a captura do gesto de forma autónoma, cuja arquitetura lógica e parâmetros de tolerância temporal serão detalhados no Capítulo de Implementação.

2.4 *Dynamic Time Warping* e Pré-Processamento do Sinal Esquelético

A comparação entre uma sequência observada e um conjunto de gestos de referência, ambos de duração variável, é um problema clássico de alinhamento temporal, cuja solução canónica é o *Dynamic Time Warping* (DTW) [Sakoe e Chiba, 1978]. Dado um par de sequências de comprimentos N e M, o DTW clássico preenche uma matriz de custo acumulado de dimensão $(N + 1) \times (M + 1)$ e encontra o percurso de menor custo entre as células $(0, 0)$ e (N, M), alinhando as duas sequências com invariância temporal. A complexidade deste procedimento é $O(N \times M)$, crescendo quadraticamente com o comprimento das sequências. Plouffe e Cretu [Plouffe e Cretu, 2016] aplicam o DTW clássico ao reconhecimento de gestos capturados por Kinect — um trabalho centrado no reconhecimento de movimentos gestuais e não no reconhecimento de língua gestual —, empregando o algoritmo não apenas como validação final mas como mecanismo de seleção de candidatos, com 92,4% de reconhecimento sobre 55 gestos. O DTW aí utilizado difere do implementado no LGPEval: não recorre a qualquer restrição global de alinhamento, o que o torna susceptível a alinhamentos patológicos (e.g., mapear um número muito reduzido de instantes do utilizador com a totalidade do molde) e apresenta custo quadrático incompatível com execução em tempo real no navegador. No LGPEval, esta limitação é resolvida com a adopção da Banda de Sakoe-Chiba [Sakoe e Chiba, 1978], que restringe o percurso de alinhamento a uma faixa diagonal de largura total $2w$ em torno da diagonal principal — isto é, o índice j é limitado ao intervalo $[i - w, i + w]$ para cada linha i —, reduzindo a complexidade para $O(N \times w)$ e impedindo os alinhamentos referidos (Figura 2.1). A formalização matemática deste mecanismo é apresentada no Capítulo 4. A fiabilidade do custo DTW depende de pré-processamento adequado do sinal. No LGPEval, a normalização da mão foi concebida originalmente para o sistema de avaliação estática, onde a invariância à translação e à escala é condição necessária para comparar posturas independentemente da distância do utilizador à câmara. A função `normalizarLandmarks` ancora o pulso na origem (invariância à translação) e normaliza todos os pontos pelo comprimento do segmento pulso–base do dedo médio (invariância à escala). Esta mesma função foi posteriormente

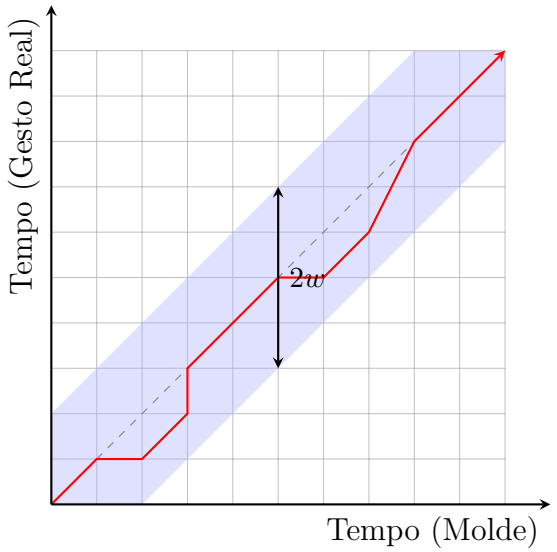


Figura 2.1: Matriz de custo DTW com restrição global da Banda de Sakoe-Chiba. A área sombreada delimita a janela de pesquisa de largura total $2w$, centrada na diagonal; o caminho a vermelho ilustra um alinhamento ótimo válido dentro da banda.

reutilizada no sistema de avaliação dinâmica, sendo aplicada a cada instante temporal antes do armazenamento nos moldes de referência e da comparação em tempo real. Arici et al. [Arici et al., 2014], num sistema Kinect de reconhecimento braço-mão, confirmam empiricamente a importância desta etapa, reportando um aumento médio de 42% no rácio discriminante quando a normalização de translação, rotação e escala do esqueleto é aplicada, o que corrobora a pertinência da abordagem adoptada.

2.5 Contextualização Espacial: da Mão ao Corpo

Nas línguas gestuais, a configuração da mão é apenas um dos parâmetros fonológicos que distinguem os gestos. Stokoe [Sakoe e Chiba, 1978] identificou, na língua gestual americana, que cada gesto é determinado pela combinação de configuração da mão, localização relativa ao corpo, movimento e orientação — a que se somam os gestos não manuais. Dois gestos podem assim partilhar a mesma configuração manual e ainda assim ser fonologica-

mente distintos, caso difiram em qualquer um dos restantes parâmetros. Esta propriedade é especialmente relevante para a localização: o mesmo formato de mão executado em zonas corporais distintas corresponde a gestos diferentes da LGP. A relevância da informação corporal e facial para o reconhecimento de gestos é também confirmada por Miah. [Baihan et al., 2024] num contexto de reconhecimento de movimentos gestuais por grafo esquelético: a inclusão de informação além da mão melhora substancialmente a precisão face a modelos exclusivamente manuais. Embora este trabalho não verse sobre língua gestual nem sobre zonas corporais específicas, confirma o benefício de integrar contexto corporal no processo de reconhecimento. A escolha das quatro zonas anatómicas utilizadas no LGPEval — Testa, Queixo, Peito e Abdómen — é motivada pelos parâmetros fonológicos da LGP e pela localização típica dos gestos do léxico implementado. Estas zonas são definidas de forma dinâmica, recalculadas a cada fotograma a partir dos *landmarks* de pose do MediaPipe, de modo a acompanhar variações de postura e distância à câmara. Um gesto executado com a configuração manual correta mas na zona corporal errada é penalizado no custo de avaliação. Complementarmente, a variável `distRelFace` codifica a distância entre o pulso e cinco pontos faciais — nariz, ouvidos e cantos da boca — extraídos dos mesmos *landmarks* de pose, sem custo computacional adicional, e é incorporada no custo DTW como medida de proximidade mão-face.

2.6 Reconhecimento em Ambiente Web sem Hardware Dedicado

Grande parte da literatura revista [Plouffe e Cretu, 2016, Arici et al., 2014] depende de sensores de profundidade dedicados (Kinect), que apresentam uma barreira de acesso considerável à distribuição de uma ferramenta pedagógica. A utilização de uma webcam padrão não elimina totalmente esta barreira, mas representa uma redução substancial face ao custo e à especificidade de instalação de um sensor de profundidade, tornando o sistema compatível com a generalidade dos computadores pessoais correntes.

O LGP-Eval assenta no MediaPipe **Holistic** [Lugaresi e et al., 2019], uma plataforma de percepção unificada que extrai, num único *pipeline* de inferência, a pose corporal (33 pontos), ambas as mãos (21 pontos cada) e

referências faciais, a partir de imagem RGB de câmara padrão, sem sensor de profundidade. Esta escolha satisfaz o requisito de ausência de hardware dedicado e permite obter, a partir da mesma chamada ao *pipeline*, os landmarks de pose e faciais necessários à contextualização espacial descrita na secção anterior, sem invocar modelos adicionais em paralelo. Todo o processamento é executado inteiramente no navegador via WebAssembly, com aceleração por GPU quando disponível, satisfazendo também os requisitos de privacidade e de ausência de infraestrutura de servidor dedicado.

2.7 Síntese e Aspetos Diferenciadores

Os problemas técnicos que sustentam o LGP-Eval encontram-se bem estabelecidos, de forma independente, na literatura. O seu contributo reside na integração coerente dessas técnicas em dois sistemas de avaliação complementares — um estático, baseado em comparação geométrica com contextualização espacial, e um dinâmico, baseado em alinhamento temporal por DTW — orientados para a avaliação pedagógica da LGP, e não para reconhecimento ou tradução. A Tabela 2.1 resume o posicionamento do LGP-Eval face às plataformas e projetos analisados. Esta distinção de propósito

Tabela 2.1: Comparação entre o LGP-Eval e outras plataformas/sistemas de ensino e tradução.

Sistema	**Língua**	**Deteção s/ Marcadores**	**Ensino Corretivo**	**Execução 100% Web**
Duolingo [Duolingo, Inc., 2026]	Várias (Orais)	N/A	N/A	Sim
HandTalk [Hand Talk, 2026]	LIBRAS—ASL—BSL	N/A (Avatar)	Não	Sim
Pocket Sign [MobiReactor, 2026]	ASL	Não (Vídeo)	Não	Não (Mobile App)
SignTutor [Aran et al., 2009]	ASL / LGTurca	Não (Luvas)	Sim	Não (Desktop/Lab)
LGP-Eval	**LGP**	**Sim**	**Sim**	**Sim**

aproxima o LGP-Eval de um precedente académico relevante: o SignTutor, de Aran et al. [Aran et al., 2009], que avalia automaticamente, por câmara, a execução de um gesto de ASL ou de Língua Gestual Turca, devolvendo feedback corretivo. O SignTutor recorre, no entanto, a luvas de cor e foi validado em laboratório controlado. O LGP-Eval alcança o mesmo objetivo sem qualquer marcador físico, executado inteiramente no navegador.

Capítulo 3

Modelo Proposto

3.1 Requisitos

Os requisitos do LGP-Eval foram definidos a partir dos dois modos de funcionamento propostos (aprendizagem e avaliação) e refinados ao longo do desenvolvimento com base em limitações técnicas e pedagógicas identificadas. A listagem completa dos onze Requisitos Funcionais e oito Requisitos Não Funcionais, o modelo de casos de utilização e a Matriz de Prioridades que orientou o escalonamento do primeiro ciclo de desenvolvimento encontram-se, na íntegra, no Apêndice A.

De entre estes, destacam-se três requisitos não funcionais, transversais a toda a arquitetura descrita neste capítulo e no Capítulo 4: o **desempenho** de processamento de vídeo capaz de garantir um *feedback* imediato ao utilizador (RNF01), a **privacidade** por processamento inteiramente local, sem envio de vídeo a servidores (RNF02), e a **portabilidade** nos navegadores de mercado mais utilizados e com suporte à captura de vídeo (RNF03). A Matriz de Prioridades (Apêndice A), construída sobre seis critérios de contributo ponderado, orientou a definição do primeiro ciclo de desenvolvimento. Em total concordância com essa análise, o caso de utilização "Executar Avaliação Estática" (64 pontos) assumiu o papel de núcleo essencial da prova de conceito pedagógica, e o caso "Calibrar Sistema" (45 pontos) foi estabelecido como o ponto de entrada imperativo do sistema.

3.2 Fundamentos

Os requisitos exigem que o sistema classifique a postura da mão e a sua localização corporal em tempo real, a partir apenas de vídeo de webcam. Esta secção estabelece os fundamentos que sustentam essa classificação, organizados em três etapas complementares: a extração de pontos-chave anatómicos, a normalização geométrica invariante à posição e à escala, e a trigonometria da postura dos dedos. A formalização do DTW é tratada em separado, na última subsecção.

O reconhecimento depende de estimar, a partir de uma imagem, a posição aproximada de estruturas anatómicas relevantes, mapeando pontos-chave (*landmarks*) por meio de modelos de IA. O LGP-Eval utiliza a biblioteca MediaPipe Holistic [Lugaresi e et al., 2019], que combina um detetor de pose corporal (33 pontos) e dois detetores de postura da mão (21 pontos cada), aplicados a regiões recortadas em torno dos pulsos. A escolha justifica-se por três razões: **execução no cliente** (WebAssembly e GPU, sem envio de vídeo a servidor, satisfazendo RNF02); **desempenho em tempo real sem hardware dedicado**, otimizado para dispositivos de consumo; e **robustez e abrangência anatómica**, com uma topologia de 21 pontos por mão e 33 corporais, perfeitamente adequada para a normalização e contextualização descritas a seguir.

Cada ponto é devolvido como uma tripla normalizada $P = (x, y, z)$, com as coordenadas x e y contidas no intervalo $[0, 1]$, representando uma percentagem da largura e da altura do fotograma, respetivamente. Uma vez que as câmaras captam vídeo num formato retangular (tipicamente 16:9 ou 4:3) e não num formato quadrado (1:1), esta normalização introduz uma distorção geométrica nas distâncias. Num fotograma retangular, uma variação de 0,1 no eixo horizontal abrange uma distância física em píxeis superior à mesma variação de 0,1 no eixo vertical. Consequentemente, o cálculo direto de ângulos ou distâncias euclidianas sobre estes valores puros resultaria numa representação da mão achatada. Esta distorção exige uma correção da proporção da imagem antes de qualquer processo de avaliação.

Sobre estes dados, a comparação direta de coordenadas entre a mão do utilizador e um molde de referência é inviável sem normalização prévia, dada a variação de translação, escala e proporção do fotograma. A normalização resolve estas fontes de variação em três passos: (1) **correção da proporção**

da câmara, ajustando o eixo horizontal pela razão largura/altura real da imagem, sem a qual as distâncias entre dedos seriam interpretadas como artificialmente esticadas; (2) **translação para a origem**, ancorando o pulso (ponto 0) em $(0, 0)$, tornando a representação invariante à posição absoluta no fotograma; e (3) **normalização de escala**, dividindo todas as coordenadas pelo comprimento euclidiano do "osso" da palma (pulso à base do dedo médio, conforme ilustrado na Figura 4.2), um segmento anatomicamente rígido, ao contrário da dimensão total da mão, garantindo escala idêntica independentemente da distância à câmara.

Por fim, como a normalização resolve a invariância à posição e à escala mas não à rotação, recorre-se a ferramentas trigonométricas complementares: o **ângulo interno numa articulação**, calculado por `atan2` entre três pontos (base, vértice, extremidade), em que um ângulo próximo de 180° corresponde a um dedo esticado e um ângulo reduzido a um dedo dobrado, suportando a deteção de erros num único dedo; e o **alinhamento rotacional global**, que roda os 21 pontos da mão do utilizador, via matriz de rotação calculada a partir da inclinação do eixo pulso–base do dedo médio, para alinhar com a orientação do molde antes de avaliar o erro absoluto ponto a ponto.

3.2.1 Contextualização Espacial: Zonas Corporais Dinâmicas

A normalização anula propositadamente a posição absoluta da mão no ecrã. Contudo, na linguística da LGP, a configuração da mão constitui apenas um dos parâmetros fonológicos. Gestos distintos podem partilhar a mesma configuração manual, distinguindo-se, entre outros fatores como o movimento e a orientação da palma, pelo local de articulação (a zona do corpo onde são executados). O LGP-Eval resolve esta ambiguidade espacial definindo quatro zonas dinâmicas (Testa, Queixo, Peito, Abdómen) em cada fotograma, ancoradas ao modelo corporal. No eixo horizontal, a distância entre os ombros define uma caixa delimitadora multiplicada por um fator de 1,8. Esta constante de expansão foi obtida através de calibração empírica durante os testes do modelo, garantindo uma margem lateral que acomoda a envergadura natural dos braços em movimento sem classificar erradamente o gesto. Qualquer ponto exterior a esta área classifica a mão com a etiqueta `"FORA"`. No eixo vertical, a distância entre o nariz e a linha dos ombros define a altura da cabeça e do pescoço, com um limite mínimo correspondente a 45% da lar-

gura dos ombros (via `Math.max`). À semelhança do multiplicador horizontal, este valor consubstancia uma heurística anatómica calibrada empiricamente para aproximar a proporção física esperada entre a altura da cabeça e a largura do tronco. Este limite inferior de segurança evita o colapso das caixas corporais caso o utilizador incline a cabeça para a frente, mantendo as quatro zonas proporcionalmente estáveis para qualquer compleição física ou distância à câmara.

3.2.2 Avaliação Dinâmica de Sequências Gestuais

Ao contrário do motor estático, focado na precisão geométrica de uma postura isolada num único instante, a avaliação dinâmica processa matrizes ordenadas de fotogramas para classificar gestos cujo parâmetro fonológico central é o movimento. A complexidade de comparar duas execuções do mesmo gesto ultrapassa a mera diferença de velocidade global entre utilizadores. Se o desafio residisse apenas na duração total do movimento, uma interpolação linear uniforme seria suficiente para normalizar o comprimento das sequências. O verdadeiro obstáculo matemático consiste nas variações temporais não lineares, como acelerações assimétricas, pequenas retenções ou ritmos distintos em fases específicas da execução. Uma correspondência estrita entre índices temporais resultaria num erro acumulado elevado, mesmo perante configurações de mão e trajetórias perfeitamente executadas. Por conseguinte, o LGP-Eval recorre ao algoritmo *Dynamic Time Warping* (DTW) para encontrar o percurso de alinhamento temporal ótimo não linear entre a sequência do utilizador $U = (u_1, \ldots, u_N)$ e a do molde $M = (m_1, \ldots, m_K)$, através da seguinte equação de recorrência:

$$D(i, j) = c(u_i, m_j) + \min\{D(i-1, j), D(i, j-1), D(i-1, j-1)\}$$

Nesta formulação matemática, $D(i, j)$ representa o custo acumulado mínimo para alinhar as sequências até aos índices i e j. O termo $c(u_i, m_j)$ define o custo local de dissimilaridade entre o fotograma u_i do utilizador e o fotograma m_j do molde. Este custo local é calculado através de uma métrica compósita que integra a diferença geométrica da mão normalizada, a divergência de zona corporal e a proximidade do pulso às referências faciais. As três parcelas do operador mínimo refletem os caminhos de alinhamento possíveis no processamento iterativo: avanço isolado no utilizador, avanço isolado no molde

ou avanço síncrono em ambas as sequências. Para garantir exequibilidade computacional em tempo real no cliente e impedir alinhamentos patológicos, impõe-se a restrição da Banda de Sakoe-Chiba, delimitando a pesquisa a $|i - j| \leq w$ e reduzindo a complexidade de $\mathcal{O}(N \times K)$ para $\mathcal{O}(N \cdot w)$. O mecanismo concreto de construção desta banda e a sua tradução em código são detalhados na Secção 4.5.

3.3 Abordagem

A abordagem organiza-se num *pipeline* linear de cinco macrofases sucessivas (Figura 3.1): captura de vídeo, extração de pontos-chave anatómicos pelo MediaPipe Holistic, normalização geométrica (bloco que encapsula as três transformações espaciais descritas na secção anterior), motor de avaliação unificado para as vertentes estática e dinâmica, e atualização da interface com feedback textual e visual.

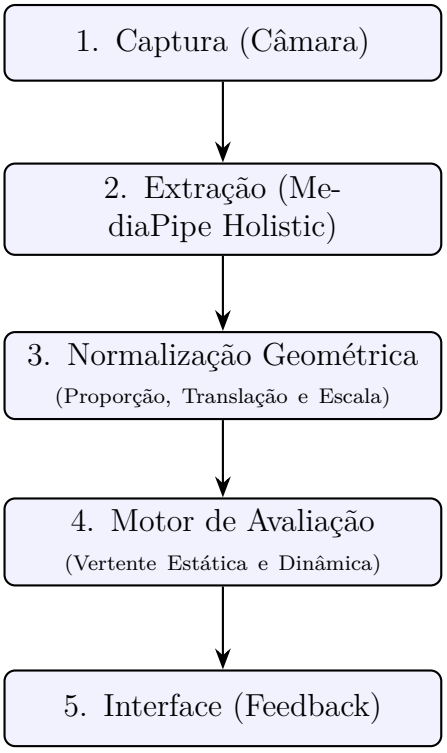


Figura 3.1: Arquitetura do *pipeline* de processamento do LGP-Eval, da captura de vídeo à decisão pedagógica.

3.3.1 Pipeline de Processamento

O ciclo executa a cada fotograma via o evento `onFrame` da biblioteca `Camera`, que invoca `holistic.send()`; o resultado é entregue assincronamente ao *callback* `holistic.onResults()`, ponto de entrada de todo o processamento subsequente, monitorizado por um contador de fotogramas por segundo. Dentro deste *callback*, o sistema separa os *landmarks* da mão direita, esquerda e da pose corporal, encaminhando cada mão detetada para a função unificadora `processarMaoUnificada`, responsável por desenhar o esqueleto, construir a representação enriquecida do fotograma (mão, zona, distâncias faciais) e invocar o motor de avaliação adequado ao estado corrente. Esta separação entre deteção, normalização e avaliação mantém os três módulos desacoplados, satisfazendo o requisito de manutenibilidade (RNF07, Apêndice A).

3.3.2 Normalização Geométrica: Justificação da Invariância à Distância

Embora o MediaPipe disponibilize opcionalmente coordenadas métricas tridimensionais no espaço do mundo (*world landmarks*), o sistema opera sobre as coordenadas bidimensionais projetadas na imagem, uma vez que o processamento decorre diretamente sobre o fluxo de vídeo RGB da câmara do utilizador. As coordenadas (x, y) fornecidas são normalizadas face às dimensões do fotograma, o que significa que a mesma configuração de dedos produz coordenadas numéricas distintas consoante a distância a que o utilizador se posiciona da câmara. Para mitigar esta dependência espacial, o sistema recorre a uma régua biométrica interna: o segmento que liga o pulso à base do dedo médio (correspondente aos *landmarks* 0 e 9, respetivamente, e ilustrado na Figura 4.2). Este segmento anatómico da palma da mão apresenta uma rigidez biomecânica superior à das falanges, sendo insuscetível à variação causada pela abertura ou fecho dos dedos. A divisão de todas as coordenadas por este comprimento euclidiano assegura a invariância à escala. Contudo, reconhece-se que esta normalização constitui uma aproximação: embora elimine o efeito da distância à câmara, persistem variações biométricas individuais na morfologia das mãos (como a proporção entre a palma e o comprimento dos dedos), uma heterogeneidade estrutural acomodada pelo suporte a múltiplos moldes de referência (*templates*) para cada

gesto. A esta normalização de escala sucede-se a translação do pulso para a origem, garantindo que a geometria relativa da mão seja avaliada de forma consistente, independentemente da sua posição no ecrã.

Capítulo 4

Implementação do Modelo

O presente capítulo descreve a concretização técnica desse modelo: as tecnologias empregues, a estrutura de dados da base de referências, a máquina de estados de segmentação, e a implementação dos dois motores de reconhecimento e da camada de feedback visual. Os excertos de código-fonte relevantes para cada função discutida encontram-se, na íntegra e organizados por secção, no Apêndice B.

4.1 Tecnologias e Dependências

O LGP-Eval foi implementado inteiramente em *JavaScript*, sem *frameworks* de interface como React ou Angular, uma decisão deliberada, motivada por três fatores.

Em primeiro lugar, o núcleo de avaliação do sistema é estritamente lógico e matemático (operações vetoriais sobre *landmarks*, cálculos trigonométricos e preenchimento de matrizes DTW), processos que operam na memória do motor de *JavaScript* independentemente do paradigma da interface gráfica. Simultaneamente, a superfície de renderização principal não assenta numa árvore HTML complexa, mas no desenho imperativo de píxeis num `HTML5 Canvas`. Como *frameworks* baseadas num *Virtual DOM* servem especificamente para otimizar atualizações de nós estruturais em HTML, a sua introdução num contexto onde o *callback* `holistic.onResults` atualiza o Canvas à taxa nativa da câmara acrescentaria um nível de abstração desnecessário e aumentaria o peso da aplicação, sem oferecer qualquer contrapartida no desempenho.

Em segundo lugar, a interface é predominantemente imperativa por natureza (navegação por menus, *toggles* lidos diretamente do DOM a cada fotograma, manipulação direta de elementos via `innerText` e `style.display`), eliminando camadas de reconciliação e mantendo controlo explícito sobre o momento de atualização de cada elemento visual, necessário quando a barra de progresso tem de estar sincronizada, fotograma a fotograma, com o motor de avaliação.

Em terceiro lugar, a ausência de *frameworks* e de *backend* é condição necessária ao cumprimento simultâneo dos requisitos de privacidade (RNF02) e de desempenho sem hardware dedicado (RNF01, Apêndice A). O sistema carrega apenas três dependências externas via CDN (`camera_utils`, `drawing_utils` e `holistic`); não existe qualquer chamada de rede subsequente ao arranque: o vídeo captado nunca abandona o navegador. Todo o processamento ocorre localmente, no motor JavaScript e no módulo WebAssembly do MediaPipe Holistic.

A instanciação do motor de perceção (Apêndice B, Excerto 1) reflete decisões de compromisso entre precisão e desempenho, diretamente ligadas ao RNF01: `modelComplexity: 1` seleciona o modelo de complexidade intermédia, evitando tanto a imprecisão do modelo leve como o custo do modelo pesado; `enableSegmentation: false` desativa a segmentação de fundo, dispensável para o sistema; `refineFaceLandmarks: false` desliga o refinamento dos 468 pontos faciais completos, uma vez que o sistema utiliza apenas os cinco pontos faciais já incluídos no modelo de pose de 33 pontos (Secção 4.5); e os limiares `minDetectionConfidence: 0.76` e `minTrackingConfidence: 0.8` foram calibrados empiricamente para reduzir falsos positivos sem penalizar excessivamente a taxa de deteção em condições de iluminação variável.

O `HTML5 Canvas` desempenha um papel duplo: é a superfície de desenho de todo o feedback visual e o mecanismo de sincronização entre a resolução real da câmara e a área de renderização, assegurado pelo *listener* `loadedmetadata` sobre `videoElement`, que redimensiona `canvasElement` para a resolução nativa assim que esta é conhecida, garantindo que as coordenadas normalizadas $[0, 1]$ do MediaPipe são convertidas para pixels sem distorção de *aspect ratio* adicional àquela já corrigida por `normalizarLandmarks` (Secção 4.4).

A Figura 4.1 ilustra a arquitetura orientada ao cliente, evidenciando o isolamento do processamento no navegador.

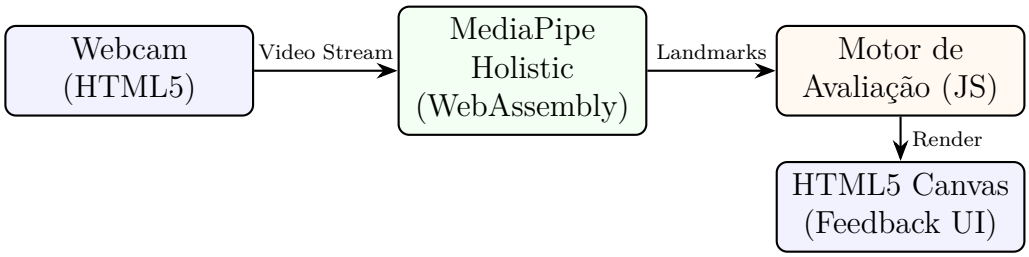


Figura 4.1: Fluxo de processamento e dependências tecnológicas isoladas no ambiente do cliente.

4.2 Estrutura de Dados e Armazenamento

A base de conhecimento do LGP-Eval é armazenada em ficheiros JSON estáticos e servida por pedidos `fetch` assíncronos. Na atual prova de conceito, estes dados são mantidos integralmente em memória nos *arrays* globais `BASE_DADOS_REFERENCIAS` (gestos estáticos) e `BASE_DADOS_DINAMICA` (gestos dinâmicos). Esta estratégia de carregamento total (*eager loading*) foi adotada para garantir latência zero durante a avaliação em tempo real, eliminando operações de leitura no disco a cada fotograma. Contudo, reconhece-se que esta abordagem apresenta um limite arquitetural de escalabilidade. Num cenário de expansão para um dicionário de escala real, o consumo de memória RAM cresceria linearmente, exigindo a futura transição para mecanismos de carregamento a pedido (*lazy loading*) ou o uso de bases de dados locais otimizadas no navegador.

A escolha do formato JSON, em detrimento de um formato binário ou de uma base de dados relacional, deve-se à correspondência direta com as estruturas nativas do JavaScript. Um objeto JSON é interpretado por `JSON.parse` diretamente como objeto JavaScript, sem camada de mapeamento intermédia, o que é relevante para um sistema sem *backend*, em que o próprio ficheiro funciona como único contrato de dados entre gravação e avaliação.

O sistema define dois formatos, correspondentes às duas vertentes do motor de avaliação (estática e dinâmica), ambos suportando múltiplas versões (*templates*) para o mesmo gesto, uma decisão que acomoda variações

biométricas, de flexibilidade articular e de inclinação natural entre diferentes utilizadores. Os exemplos completos de ambos os formatos encontram-se no Apêndice A; descreve-se aqui apenas a sua estrutura lógica.

O **formato estático**, gerado por `gravarReferencia` e descarregado com o sufixo `_template.json`, contém um objeto com o campo `pontos` (21 *landmarks* já normalizados) e o campo `corpo` (coordenadas *raw* do nariz, ombros e âncora da mão), usado por `calcularZonaDinamica` para reconstituir a zona alvo desse molde. O **formato dinâmico**, gerado por `exportarGestoDinamico` e descarregado com o sufixo `_dinamico.json`, contém `nome`, `versao_formato` e `frames`: um *array* de objetos {`mao, zona, corpo, distRelFace`}, um por fotograma capturado.

O carregamento é assíncrono e sequencial no arranque (`carregarTodasAsReferencias` e `carregarReferenciasDinamicas`), com *cache-busting* por *timestamp*, garantindo que alterações à base durante o desenvolvimento são refletidas sem invalidação manual de *cache*. Esta arquitetura satisfaz o requisito de desacoplamento de dados (RNF06). Sendo uma aplicação executada inteiramente do lado do cliente (*client-side*), a expansão do léxico assume um carácter administrativo ao nível do código-fonte local: a integração de um novo gesto resume-se a alocar o respetivo ficheiro JSON no repositório do projeto e acrescentar a sua referência ao *array* de configuração, não exigindo qualquer alteração à lógica interna dos motores de comparação.

4.3 Gestão de Estados e Segmentação Automática

O comportamento do LGP-Eval é regido por um pequeno conjunto de variáveis de estado globais. A variável `estadoApp` assume um de sete valores (`"CALIBRACAO"`, `"AVALIACAO"`, `"AVALIACAO_DINAMICA"`, `"GRAVACAO_DINAMICA"`, `"PRE_GRAVACAO"`, ou `null`) e funciona como principal ponto de ramificação do *callback* `holistic.onResults`, determinando se a mão detetada é encaminhada para a calibração, o motor estático, ou o *buffer* dinâmico.

A segmentação de gestos dinâmicos é implementada como uma máquina de estados finita independente por mão (`estadoSegmentacao` = {`'Right': 'REPOUSO', 'Left': 'REPOUSO'`}), com a lógica de transição implemen-

tada dentro de `processarMaoUnificada`. A transição de `REPOUSO` para `GRAVANDO` ocorre quando a zona corporal atual deixa de ser "FORA" ou "ABDÓMEN"; a variável `maoAtivaDTW` impõe que apenas uma mão alimente o motor DTW de cada vez, coerente com o pressuposto de gestos dinâmicos unimanuais. Enquanto `GRAVANDO`, cada fotograma é empacotado e adicionado ao *buffer*, limitado a `TAMANHO_MAX_BUFFER = 150` (cerca de cinco segundos a 30 fps), implementando um *buffer* circular.

A transição de `GRAVANDO` para `DEBOUNCE` ocorre quando a mão regressa à zona de repouso; em vez de finalizar imediatamente, o sistema agenda a avaliação por `setTimeout` (excerto de código no Apêndice B, Excerto 2). A constante `DEBOUNCE_MS = 400` define a janela de tolerância: se, durante os 400 ms, a mão voltar a abandonar a zona de repouso, o estado reverte para `GRAVANDO`, cancelando o temporizador pendente e evitando fragmentação prematura. Caso contrário, o temporizador expira e invoca `dispararAvaliacaoDTW`, que repõe o estado a `REPOUSO`, liberta `maoAtivaDTW` e submete o *buffer* ao motor DTW (Secção 4.5). Esta mesma lógica é replicada, de forma simplificada, nos ramos de ausência de deteção de mão do *callback* principal, tratando a saída do campo visual da câmara como equivalente ao regresso à zona de repouso, garantindo robustez (RNF04) perante perdas momentâneas de *tracking*.

4.4 Implementação do Motor Estático

O motor de avaliação estática assenta em três funções sucessivas:
`normalizarLandmarks`, que resolve a invariância geométrica;
`identificarZonaArticulacao`, que resolve a contextualização espacial; e `classificarGestoPorReferencia`, que integra ambas.

Normalização Geométrica

A função `normalizarLandmarks` (Apêndice B, Excerto 3) traduz para código os princípios matemáticos já estabelecidos na Secção 3.2. Esta rotina é reutilizada integralmente tanto na avaliação em tempo real quanto na gravação de novas referências, garantindo que os moldes e as poses capturadas partilham o mesmo espaço de representação invariante.

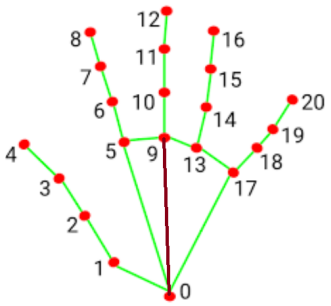


Figura 4.2: Modelo esquelético da mão, com destaque para o osso da palma (pulso, ponto 0, à base do dedo médio, ponto 9), adotado como régua biométrica para a normalização de escala.

Contextualização Espacial

A função `identificarZonaArticulacao` operacionaliza a lógica de mapeamento corporal definida na Secção 3.2, delegando o cálculo vetorial na função auxiliar `calcularZonaDinamica`. Este método é invocado tanto para classificar a posição atual em tempo real como para reconstituir a zona alvo esperada a partir do campo `corpo` de cada molde. Esta centralização de código evita a duplicação de regras lógicas e assegura a consistência espacial contínua do sistema.

Classificação por Comparação de Referência

A função `classificarGestoPorReferencia` constitui o núcleo de decisão. Inicialmente, a função normaliza a mão testada e espelha as suas coordenadas geométricas caso se trate da mão esquerda. Esta identificação de lateralidade não exige cálculos algorítmicos adicionais, sendo obtida diretamente através da separação nativa dos dados fornecida pelo motor *MediaPipe Holistic* (que isola previamente as deteções nas estruturas `leftHandLandmarks` e `rightHandLandmarks`). Após esta preparação, a função itera sobre o subconjunto de referências relevante. Para cada candidata, executa três operações: (1) calcula o desvio angular entre a orientação da mão testada e da referência; se exceder `TOLERANCIA_RADIANOS` (50°), a referência é rejeitada com

`motivo: "Ângulo"`; (2) roda os 21 pontos pela matriz de rotação correspondente e calcula a distância euclidiana média ao molde (`erroFinal`), registando o maior desvio pontual (`erroMaximoNestaRef`); (3) recalcula a zona alvo do molde e soma uma penalização fixa de 0,30 em caso de divergência de zona.

O reconhecimento só é confirmado se três condições forem simultaneamente satisfeitas: erro médio inferior a `LIMITE_ACEITACAO_MEDIO` (0,25), erro máximo pontual inferior a `LIMITE_CRITICO_PONTO` (0,42), e ausência de rejeição angular. Esta dupla verificação impede que um único dedo mal posicionado seja "diluído" pela média dos restantes 20 pontos, permitindo o feedback específico (RF09, Apêndice A) via `obterNomeDoPonto`.

Fragmento do código

4.5 Implementação do Motor Dinâmico

O motor dinâmico é acionado por `dispararAvaliacaoDTW` ao expirar o temporizador de *debounce*. Após confirmar um mínimo de oito *frames*, a função itera sobre `BASE_DADOS_DINAMICA`, invocando `calcularDTW` para cada molde e retendo o de menor custo; o gesto é reconhecido se este custo for inferior a `LIMITE_ACEITACAO_DTW` (0,25).

Como justificado na revisão da literatura, o LGP-Eval não recorre à modelação estatística do *Movement Epenthesis*. Em alternativa, implementou-se uma máquina de estados finita híbrida de três fases, ancorada à zona de repouso corporal (o abdómen), para delimitar a captura do gesto (Figura 4.3).

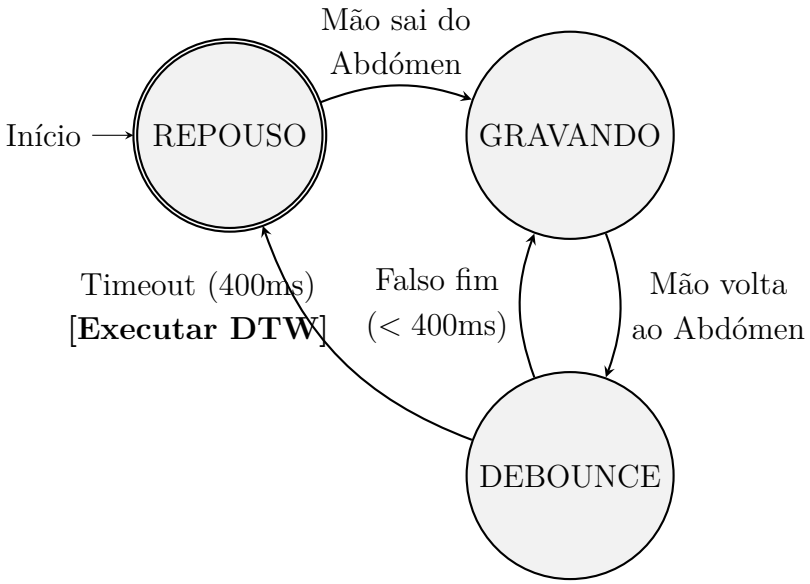


Figura 4.3: Máquina de estados híbrida para segmentação temporal autónoma de gestos dinâmicos.

A saída da mão da zona de repouso desencadeia a gravação; o regresso a essa zona, após um período de *debounce* de 400 ms destinado a absorver oscilações espúrias na fronteira do gesto, desencadeia a avaliação pelo motor de *Dynamic Time Warping* (DTW). Esta heurística espacial de baixo custo substitui a modelação explícita de transições, revelando-se altamente adequada a um cenário de execução do lado do cliente sem base de dados de gestos negativos.

A Matriz de Custos e a Banda de Sakoe-Chiba

É neste ponto do sistema que a restrição da Banda de Sakoe-Chiba, já introduzida na Secção 3.2, se torna um mecanismo concreto de computação. Vale por isso a pena detalhar, passo a passo, como a função `calcularDTW` (Apêndice B, Excerto 4) constrói e preenche esta matriz.

Sem qualquer restrição, o algoritmo DTW exigiria o preenchimento de uma matriz `dtw` de dimensão $(N{+}1) \times (M{+}1)$, em que cada célula $dtw[i][j]$ representa o custo acumulado mínimo para alinhar os primeiros i fotogramas da sequência do utilizador com os primeiros j fotogramas do molde. A célula `dtw[0][0] = 0` constitui o caso base: alinhar duas sequências vazias não tem

custo. O preenchimento exaustivo desta matriz, célula a célula, tem complexidade $\mathcal{O}(N \times M)$, o que se torna incomportável quando N e M ascendem às centenas de fotogramas exigidas por um gesto dinâmico capturado a 30 fps.

A observação central de Sakoe e Chiba [Sakoe e Chiba, 1978] é que, para sequências que representam o mesmo gesto executado a velocidades fisiologicamente plausíveis, o percurso de alinhamento ótimo nunca se afasta muito da diagonal principal da matriz. Um utilizador pode executar o gesto ligeiramente mais depressa ou mais devagar que o molde, mas não a um ponto em que o fotograma 5 do utilizador corresponda, por exemplo, ao fotograma 80 do molde. Esta observação permite substituir o preenchimento total da matriz pelo preenchimento de uma faixa diagonal de largura w, ilustrada na Figura 2.1, fora da qual nenhuma célula é sequer calculada.

No código, esta faixa é implementada calculando, para cada linha i, os limites `jMin` e `jMax` que delimitam as colunas a processar nessa linha: `jMin = Math.max(1, i - banda)` e `jMax = Math.min(M, i + banda)`. Por outras palavras, em vez de percorrer as M colunas da linha i, o ciclo interno percorre apenas o intervalo $[i - w,\ i + w]$, o que reduz o número de células calculadas por linha de M para, no máximo, $2w + 1$, e a complexidade total do algoritmo de $\mathcal{O}(N \times M)$ para $\mathcal{O}(N \cdot w)$.

A Tabela 4.1 ilustra esta construção para um caso reduzido ($N = 5$, $M = 7$, $w = 1$), tornando visível como a faixa de células efetivamente calculadas (marcadas com $\bullet$) se estreita em torno da diagonal, poupando o cálculo das restantes células (assinaladas com –) sem comprometer a validade do alinhamento.

Tabela 4.1: Exemplo reduzido da banda de Sakoe-Chiba ($N = 5$, $M = 7$, $w = 1$, banda $= \max(w, |N - M|) = 2$).

	j=1	j=2	j=3	j=4	j=5	j=6	j=7
i=1	$\bullet$	$\bullet$	$\bullet$	–	–	–	–
i=2	$\bullet$	$\bullet$	$\bullet$	$\bullet$	–	–	–
i=3	$\bullet$	$\bullet$	$\bullet$	$\bullet$	$\bullet$	–	–
i=4	–	$\bullet$	$\bullet$	$\bullet$	$\bullet$	$\bullet$	–
i=5	–	–	$\bullet$	$\bullet$	$\bullet$	$\bullet$	$\bullet$

Neste exemplo, das 35 células da matriz completa (5×7), apenas 22 são efetivamente calculadas: uma redução modesta à escala do exemplo, mas que

cresce de forma proporcional a N e M em sequências reais de várias centenas de fotogramas.

Uma faixa de largura fixa w é insuficiente quando N e M diferem significativamente: se o utilizador demorar consideravelmente mais ou menos tempo que o molde a executar o gesto, uma banda estreita poderia nunca alcançar a célula final $dtw[N][M]$, deixando o algoritmo sem qualquer percurso válido entre $(0, 0)$ e (N, M). É por isso que o código calcula `banda = Math.max(w, |N-M|)`: a largura efetiva da faixa nunca é inferior à diferença de comprimento entre as duas sequências, garantindo sempre a existência de, pelo menos, um percurso diagonal válido que ligue os dois extremos da matriz, independentemente da discrepância temporal entre a execução do utilizador e o molde de referência.

Para cada célula (i, j) dentro dos limites `[jMin, jMax]`, o custo é calculado como a soma do custo local $c(u_i, m_j)$ (Secção seguinte) com o mínimo dos três percursos possíveis que a alcançam: $dtw[i-1][j]$, que absorve um fotograma extra do utilizador sem avançar no molde (o utilizador está momentaneamente mais lento que o molde); $dtw[i][j-1]$, que absorve um fotograma extra do molde sem avançar no utilizador (o utilizador está momentaneamente mais rápido); e $dtw[i-1][j-1]$, que avança em sincronia nas duas sequências. Esta escolha local, replicada célula a célula ao longo de toda a faixa, é o que permite ao algoritmo absorver variações não lineares de ritmo sem penalizar gestos corretos executados a velocidades distintas (Secção 3.2).

O valor de w utilizado no LGP-Eval (10 fotogramas, equivalente a cerca de 333 ms a 30 fps) resulta de um compromisso empírico: um valor demasiado baixo restringe excessivamente a tolerância a variações de ritmo entre utilizadores, penalizando gestos corretos executados de forma ligeiramente mais lenta ou rápida; um valor demasiado alto aproxima o custo computacional do da matriz completa e aumenta o risco de o algoritmo encontrar alinhamentos patológicos, em que uma sequência é distorcida de forma pouco natural apenas para minimizar o custo total. O valor final, tal como os limiares de aceitação descritos na Secção 4.4, foi calibrado empiricamente durante o segundo ciclo de validação (Secção 3.3).

O Custo de Dissimilaridade entre Fotogramas

A métrica de custo local, implementada em `calcularCustoEntreDuasFrames` (Apêndice B, Excerto 5), combina três componentes aditivas. A primeira, `erroGeometrico`, replica a distância euclidiana média usada no motor estático, aplicada aos *frames* `mao` de ambas as sequências.

A segunda componente é a penalização de zona. Uma vez que o algoritmo DTW avalia a dissimilaridade iterando fotograma a fotograma, o sistema suporta nativamente gestos dinâmicos que atravessam múltiplas zonas corporais. Esta penalização é discreta e deliberadamente elevada (1,20), sendo aplicada individualmente apenas quando a zona registada no fotograma do utilizador diverge da zona no fotograma homólogo do molde. Este valor foi calibrado para garantir que, ao ser somado ao longo da sequência e normalizado por $(N+M)$, o custo final exceda o limiar de aceitação caso o utilizador execute o movimento numa área errada do corpo.

A terceira componente, `erroFacial`, é calculada a partir do vetor `distRelFace` (Apêndice B, Excerto 6). Esta métrica avalia a distância euclidiana do pulso a cinco pontos faciais de pose (nariz, ouvidos e cantos da boca, dados pela constante `POSE_FACE_INDICES = [0, 7, 8, 9, 10]`). O cálculo reaproveita os dados espaciais já extraídos pelo motor base do *MediaPipe*, apresentando um impacto computacional reduzido no ciclo de processamento. Quando a mão processada é a esquerda, os índices laterais são trocados entre si para garantir simetria com os moldes, gravados exclusivamente com a mão direita. Este mapeamento vetorial das distâncias relativas entre o pulso e os referidos pontos faciais encontra-se ilustrado na Figura 4.4.

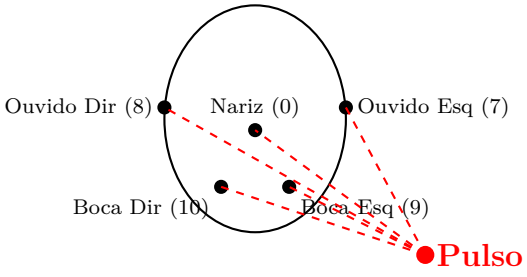


Figura 4.4: Mapeamento vetorial das cinco distâncias relativas (`distRelFace`) utilizadas na avaliação de gestos dinâmicos.

4.6 Sincronização Visual e Feedback

Todo o feedback visual é redesenhado do zero em cada fotograma, dentro do *callback* `holistic.onResults`, pela sequência `save()` → `clearRect()` → `drawImage()` → camadas de desenho → `restore()`. Esta abordagem de *immediate mode rendering* é coerente com a natureza do `HTML5 Canvas` e garante que o estado visual nunca diverge do estado de dados subjacente, eliminando qualquer reconciliação.

As camadas de desenho respeitam uma hierarquia de profundidade visual: o esqueleto fantasma (`desenharEsqueletoFantasma`), desenhado apenas em modo de treino dirigido com o *toggle* ativo, é traçado *antes* do corpo, com `globalAlpha = 0.4`, permanecendo subordinado à imagem real da câmara; as zonas corporais (`desenharZonasArticulacao`) materializam a lógica de `calcularZonaDinamica` em quatro retângulos tracejados coloridos, calculados com as mesmas fórmulas do motor de classificação; e a bússola de inclinação (`desenharBussola`) representa o desvio rotacional com um arco de $\pm 50°$ em torno do ângulo ideal.

A atualização do painel HTML de progresso é feita por `atualizarFeedbackHTML` (Apêndice B, Excerto 7), que mapeia o erro decimal, por interpolação linear entre os limiares 0,10 e 0,40, para uma percentagem de preenchimento da barra de progresso, também determinando a sua cor e o texto de estado. Este processo traduz a métrica interna do motor numa escala de progresso compreensível a um utilizador leigo, concretizando o requisito de usabilidade (RNF05). A conjugação de todas estas camadas de informação resulta na interface de treino final ilustrada na Figura 4.5.

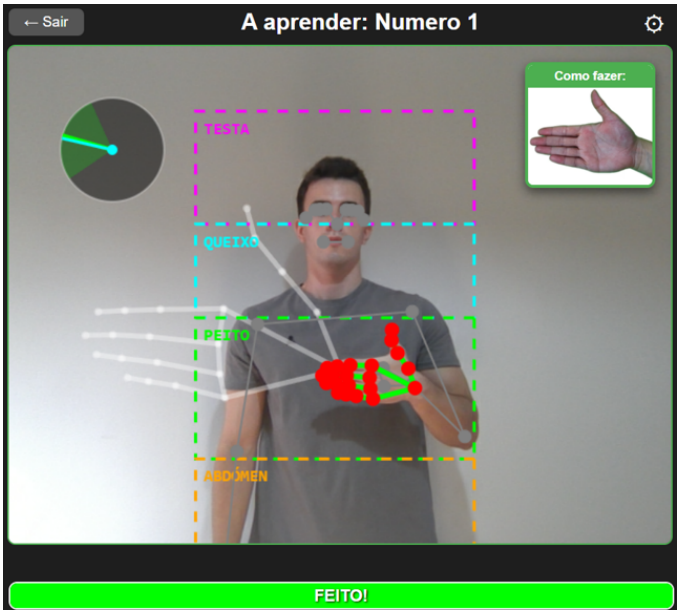


Figura 4.5: Interface de treino do LGP-Eval, demonstrando a sobreposição de elementos no `Canvas`: esqueleto fantasma, zonas corporais delimitadas, bússola de inclinação, fotografia do gesto e barra de progresso.

Capítulo 5

Validação e Testes

Os Capítulos 3 e 4 estabeleceram o modelo teórico e a concretização técnica do LGP-Eval. O presente capítulo desloca o foco para a validação externa da ferramenta enquanto artefacto pedagógico, avaliado por utilizadores reais, uma vez que um motor matematicamente correto não garante, por si só, que a ferramenta seja utilizável e eficaz para o público-alvo. Conduziu-se, para isso, um estudo empírico de usabilidade.

5.1 Metodologia e Perfil dos Utilizadores

O estudo foi conduzido junto de sete participantes ($N = 7$), num protocolo de duas fases: uma sessão de interação direta, na qual cada participante executou uma tarefa de treino estático dirigido a um gesto específico (o número dois), seguida de um questionário estruturado combinando perceção qualitativa com os dez itens da *System Usability Scale* (SUS), analisada na Secção 5.3.

A amostra concentrou-se em faixas etárias mais maduras (um participante entre 18–24, dois entre 25–34, quatro com 45 ou mais anos), com áreas profissionais heterogéneas: gestão hoteleira, recursos humanos, TI e engenharia, saúde/emergência médica, e estética. À exceção do participante de engenharia informática, nenhum tinha relação prévia com tecnologia ou ciências da computação, e a totalidade declarou não possuir qualquer familiaridade prévia com a LGP, seis dos sete nunca tendo tentado aprender qualquer língua gestual.

Este perfil (leigo tanto no domínio técnico como linguístico) não é uma

limitação, mas a condição experimental mais adequada para validar o requisito de usabilidade RNF05, que exige que um utilizador sem conhecimentos técnicos consiga iniciar uma sessão de treino em poucos passos. Uma amostra de especialistas introduziria um enviesamento favorável, mascarando falhas de usabilidade que só se manifestam num primeiro contacto genuíno.

5.2 Avaliação Prática e Qualitativa

A primeira dimensão de análise incide sobre o desempenho objetivo na tarefa e a perceção imediata da experiência, medida por quatro indicadores: a conclusão bem-sucedida da tarefa, a clareza do feedback no reconhecimento correto, o atraso percecionado entre movimento e resposta, e a probabilidade de recomendação (NPS).

A totalidade dos sete participantes (100%) concluiu com sucesso a tarefa proposta, corroborando a robustez do motor de classificação geométrica mesmo perante utilizadores sem preparação prévia. Quanto à clareza do momento de validação, cinco participantes atribuíram a pontuação máxima (5/5) e dois atribuíram 3/5, sugerindo que o mecanismo de feedback multinível é largamente eficaz mas ainda deixa margem de ambiguidade para alguns utilizadores. No reconhecimento em modo de avaliação livre, seis dos sete reportaram precisão, enquanto um relatou confusões entre números, uma discrepância retomada na Secção 5.4. Quanto ao atraso percecionado, cinco participantes atribuíram a pontuação mínima (1/5) e dois 2/5, validando empiricamente o requisito de tempo real (RNF01) e a eficácia da Banda de Sakoe-Chiba. Quanto ao NPS, três participantes atribuíram 10/10 e os restantes quatro 9/10, sem qualquer classificação abaixo de 9.

A Tabela 5.1 sintetiza estes indicadores por participante.

Tabela 5.1: Indicadores qualitativos de desempenho e perceção prática por participante.

Participante	**Sucesso na Tarefa**	**Clareza do Feedback (1–5)**	**Atraso Percecionado (1–5)**	**NPS (0–10)**
P1	Sim	5	2	9
P2	Sim	5	1	9
P3	Sim	5	1	9
P4	Sim	5	1	9
P5	Sim	5	2	10
P6	Sim	3	1	10
P7	Sim	3	1	10
Taxa/Média	**100%**	**4,4 / 5**	**1,3 / 5**	**9,4 / 10**

A leitura conjunta traça um perfil de usabilidade prática consistente: a tarefa é acessível na totalidade a um utilizador leigo, o desempenho em tempo real não constitui, na generalidade, uma barreira percecionada, e a satisfação global (NPS) é uniformemente elevada, sem qualquer classificação detratora. A atribuição do NPS máximo por P5, P6 e P7 não impede que P6 e P7 tenham reportado, noutras dimensões, dificuldades específicas discutidas na Secção 5.4: uma recomendação entusiástica é compatível com a identificação de pontos de fricção pontuais.

5.3 Avaliação Quantitativa de Usabilidade (SUS)

Aplicou-se a cada participante o questionário *System Usability Scale* (SUS), dez itens alternando valência positiva e negativa, cada um pontuado de 1 a 5. A pontuação final segue a fórmula de normalização padrão: para itens positivos (ímpares) subtrai-se uma unidade à pontuação bruta; para negativos (pares) subtrai-se a pontuação a cinco; a soma dos dez valores é multiplicada por 2,5, produzindo um resultado em $[0, 100]$.

A Tabela 5.2 apresenta o perfil demográfico e a pontuação SUS individual de cada participante.

Tabela 5.2: Perfil demográfico dos participantes e pontuação SUS individual.

Participante	**Género**	**Faixa Etária**	**Área de Atuação**	**Pontuação SUS**
P1	Masculino	45 ou mais	Gestão Hoteleira	90,0
P2	Feminino	25–34	Recursos Humanos	95,0
P3	Feminino	45 ou mais	Gestão Hoteleira	90,0
P4	Masculino	25–34	Engenharia / TI	97,5
P5	Feminino	18–24	Saúde / Emergência Médica	95,0
P6	Feminino	45 ou mais	Estética	92,5
P7	Masculino	45 ou mais	Gestão	65,0
			Pontuação SUS Média do Sistema	**89,3**

A pontuação média de 89,3/100 situa o LGP-Eval numa posição francamente favorável face aos valores de referência da literatura: é consensual, desde os trabalhos de Bangor, Kortum e Miller, que uma pontuação ≥ 68 corresponde a usabilidade acima da média, e que pontuações entre 80 e 100 correspondem a uma classificação de "excelente" (grau A). O valor obtido ultrapassa folgadamente o limiar de aceitabilidade, denotando facilidade de utilização notável para um sistema dependente de visão computacional em

tempo real, categoria tipicamente mais suscetível a fricções de usabilidade do que interfaces textuais, dada a sua dependência de condições ambientais e da precisão do próprio utilizador.

A distribuição individual revela, no entanto, um desvio estatístico: seis dos sete participantes obtiveram pontuações entre 90,0 e 97,5, um agrupamento excecionalmente consistente, enquanto P7 se destacou com 65,0, quase 25 pontos abaixo da média e ligeiramente abaixo do próprio limiar de aceitabilidade. Este afastamento não decorre de insucesso na tarefa (P7 completou o treino e atribuiu NPS máximo), mas de um padrão claro de discordância moderada nos itens relacionados com integração, consistência e curva de aprendizagem. Cruzando este padrão com a sugestão de P7 de uma "transição automática" entre exercícios, o *outlier* relaciona-se diretamente com a quebra de ritmo introduzida pela necessidade de regressar manualmente ao menu principal, discutida na Secção 5.4 e retomada na Secção 6.2.

5.4 Análise Crítica e Dificuldades

A análise das respostas abertas revela quatro categorias de fricção, cuja origem técnica importa dissecar.

Latência Percecionada no Arranque

Um participante (P3) descreveu o arranque como aparentando o computador "lento/travado". Esta perceção é tecnicamente explicável: o arranque envolve o carregamento e inicialização, via WebAssembly, do modelo completo do MediaPipe Holistic (três subsistemas de estimação), em paralelo com o pedido de permissão de câmara, um processo local e coerente com o RNF02, mas sem qualquer indicador visual de progresso atualmente, o que é suficiente para um utilizador leigo interpretar um curto silêncio visual como sintoma de avaria.

Quebra de Fluxo na Navegação entre Exercícios

A dificuldade mais consistentemente reportada, diretamente relacionada com o *outlier* de P7, prende-se com a navegação entre exercícios: como P1 sintetizou, "voltar ao menu para mudar de exercício implica mexer no rato e isso

quebra um pouco o ritmo". Isto decorre de uma decisão de arquitetura: a navegação é gerida por funções de apresentação/ocultação de *views* sem qualquer transição direta entre dois exercícios do mesmo tipo, obrigando a invocar `voltarAoMenu()` a cada transição, uma lacuna deliberada de âmbito na primeira iteração, priorizada segundo a Matriz de Prioridades (Apêndice A) em favor da validação do motor de avaliação estática.

Sensibilidade a Condições de Iluminação e Posicionamento

P5 e P6 reportaram dificuldades na deteção inicial da mão, relacionadas com iluminação e posicionamento perante a câmara, consequência esperada da natureza monocular do MediaPipe Holistic, que infere a posição tridimensional exclusivamente a partir de imagem RGB bidimensional, ao contrário de sistemas com sensores de profundidade dedicados. Esta é a compensação inerente à decisão de privilegiar acessibilidade (RNF01, RNF03) em detrimento de robustez geométrica incondicional; ambas as participantes conseguiram, após ajuste, completar a tarefa com sucesso.

Poluição Visual do Esqueleto Fantasma

P2 assinalou que "o esqueleto fantasma pareceu-me pouco útil durante a aprendizagem e ocupava demasiado espaço no ecrã". A sobreposição simultânea de esqueleto fantasma, zonas corporais, bússola de inclinação e a fotografia do gesto satura o campo visual. Embora o sistema já disponibilize ativação/desativação individual de cada ajuda (RF10), a configuração predefinida apresenta todas ativas, transferindo para o utilizador leigo o ónus de descobrir e gerir essa personalização por iniciativa própria.

Capítulo 6

Conclusões e Trabalho Futuro

6.1 Síntese e Conclusões

O presente projeto propôs o desenho e a implementação do LGP-Eval, uma ferramenta de ensino interativo orientada à correção autónoma de vocabulário da Língua Gestual Portuguesa. A motivação central partiu da lacuna em ferramentas de *CALL* para LGP que oferecessem ensino corretivo em tempo real, em oposição a dicionários passivos ou tradutores automáticos.

Os objetivos estabelecidos foram integralmente cumpridos. A prova de conceito demonstra ser possível extrair métricas geométricas complexas (ângulos de falanges e contextualização espacial em áreas do tronco e face) em tempo real, sem recurso a equipamento de profundidade ou luvas instrumentadas. O principal contributo técnico reside na arquitetura híbrida orientada à privacidade: combinando MediaPipe Holistic com algoritmos de programação dinâmica (DTW com restrição de Sakoe-Chiba) inteiramente em *JavaScript* e WebAssembly, o sistema garante que todo o processamento de vídeo ocorre localmente, sem dependência de servidores externos.

A avaliação empírica de usabilidade corroborou o sucesso da abordagem: a pontuação SUS média de 89,3, junto de um público sem experiência prévia com a LGP, valida a eficácia do feedback visual e a robustez pedagógica do sistema. O LGP-Eval afirma-se, assim, não como um produto fechado, mas como uma base tecnológica sólida para soluções pedagógicas digitais acessíveis e escaláveis.

6.2 Trabalho Futuro

As dificuldades identificadas na Secção 5.4, conjugadas com as sugestões espontâneas dos participantes, permitem delinear três eixos de evolução arquitetural rastreáveis a fricções empíricas documentadas.

Eliminação da Quebra de Ritmo na Transição entre Exercícios

Sendo a fricção mais reportada, a sua resolução deve ser prioritária no próximo ciclo. As sugestões dos participantes (botões direcionais no ecrã de treino, um menu lateral expansível, atalhos de teclado, ou transição automática ao preencher a barra de progresso) apontam para a mesma solução arquitetural: desacoplar a troca de `gestoAlvo` do ciclo completo de `voltarAoMenu` e `iniciarTreino`. Propõe-se uma nova função `trocarGestoAlvo`, que atualize apenas `gestoAlvo` e o painel de progresso sem interromper a sessão de vídeo ativa, invocável por botões de navegação sobrepostos ao *canvas* ou por um *listener* de teclado.

Onboarding e Mitigação de Condições Ambientais Adversas

Propõe-se estender `executarCalibracaoUI` com uma verificação da confiança de deteção do MediaPipe ao longo de uma janela de fotogramas; se persistentemente baixa, o sistema sugeriria proativamente um ajuste (ex. aproximar-se de uma fonte de luz frontal), operacionalizando a sugestão de um participante para um breve tutorial de posicionamento e iluminação antes do início.

Gamificação como Mecanismo de Retenção

A sugestão de um "modo de desafio ou pontuação, estilo Duolingo" aponta para um mecanismo de motivação a longo prazo, implementável como camada adicional desacoplada do motor de avaliação geométrica, consumindo o erro e a confirmação de reconhecimento para alimentar um sistema de pontuação e progressão por níveis, garantindo regresso frequente dos utilizadores à plataforma.

Apêndice A

Especificação de Requisitos e Casos de Utilização

Este apêndice detalha os requisitos funcionais e não funcionais estabelecidos e aplicados no desenvolvimento da prova de conceito do LGP-Eval. O capítulo inclui, de igual modo, a modelação formal dos casos de utilização e a matriz de prioridades, cuja pontuação ditou o escalonamento do ciclo inicial de engenharia.

A.1 Requisitos Funcionais

- **RF01**: O sistema deve captar, em tempo real, os pontos de articulação das mãos e do corpo do utilizador através da câmara do dispositivo.
- **RF02**: O sistema deve executar uma calibração inicial, confirmando que a mão do utilizador é detetada antes de iniciar a avaliação.
- **RF03**: O sistema deve disponibilizar um modo de Aprendizagem, no qual o utilizador escolhe o gesto que pretende treinar.
- **RF04**: Durante o treino, o sistema deve disponibilizar um conjunto de ajudas visuais pedagógicas sobrepostas à imagem da câmara, integrando num mesmo contexto: o esqueleto fantasma da configuração da mão (apenas em gestos estáticos), a bússola de inclinação (apenas gestos estáticos), a delimitação visual das zonas corporais (*bounding boxes*) e a fotografia ilustrativa do gesto.

- **RF05**: O sistema deve disponibilizar um modo de Avaliação capaz de identificar automaticamente a execução tanto de gestos estáticos como de gestos dinâmicos.
- **RF06**: O sistema deve verificar a posição da mão relativamente ao corpo do utilizador, com base em zonas corporais delimitadas pelas proporções do utilizador.
- **RF07**: O sistema deve segmentar automaticamente um gesto dinâmico, sem intervenção manual do utilizador.
- **RF08**: O sistema deve comparar a sequência de movimento capturada com uma base de dados de referências dinâmicas.
- **RF09**: O sistema deve devolver feedback textual específico sobre o erro identificado.
- **RF10**: O sistema deve permitir ao utilizador ativar ou desativar, individualmente, cada uma das ajudas visuais disponíveis.
- **RF11**: O sistema deve disponibilizar uma ferramenta de captura que permita exportar localmente a geometria de novos gestos em formato JSON. Tratando-se de uma aplicação executada inteiramente no dispositivo do cliente (*client-side*), esta exportação local não altera o léxico global da plataforma. A integração efetiva de novos ficheiros na base de dados oficial constitui um processo externo à interface (*out-of-band*), realizado manualmente ao nível do código-fonte, garantindo o controlo de qualidade.

A.2 Requisitos Não Funcionais

- **RNF01 (Desempenho)**: O motor de deteção e avaliação deve processar o fluxo de vídeo a uma taxa de fotogramas que garanta feedback percecionado pelo utilizador como imediato.
- **RNF02 (Privacidade)**: O processamento do vídeo deve ocorrer inteiramente no dispositivo do utilizador, sem envio de imagem ou vídeo para servidores externos.

- **RNF03 (Portabilidade)**: O sistema deve funcionar nos navegadores de mercado mais utilizados e com suporte à captura de vídeo, sem necessidade de instalação de software adicional.
- **RNF04 (Robustez e Tolerância a Falhas)**: O sistema deve suspender a classificação geométrica perante a perda de rastreio da mão do utilizador, rejeitando a emissão de falsos positivos e retomando a avaliação apenas quando a confiança de deteção for restabelecida.
- **RNF05 (Usabilidade)**: A interface deve permitir a um utilizador sem conhecimentos técnicos iniciar uma sessão de treino em poucos passos.
- **RNF06 (Desacoplamento de Dados)**: A injeção de novo vocabulário no sistema deve ser feita de forma declarativa, através da inclusão de ficheiros estruturados independentes (JSON), não exigindo a recompilação da aplicação nem a criação de regras lógicas específicas (*hardcoding*) para cada novo gesto, dentro dos limites de escalabilidade computacional do algoritmo DTW no lado do cliente.
- **RNF07 (Manutenibilidade e Desacoplamento)**: A arquitetura do código deve respeitar o princípio da Separação de Preocupações (*Separation of Concerns*), garantindo que o motor matemático de geometria, a máquina de estados e as funções de manipulação da interface operam como módulos isolados no *pipeline* de processamento.
- **RNF08 (Capacidade Computacional)**: O sistema deve garantir a execução fluida do modelo de visão computacional mantendo um desempenho aceitável num conjunto definido de dispositivos de consumo, salvaguardando que o processamento estritamente local (exigido pelo RNF02) não inviabiliza a utilização em computadores de gama média.

A.3 Modelo de Casos de Utilização

O modelo de casos de utilização identifica um único ator principal, o Utilizador (Aprendiz de LGP), responsável por toda a interação com o sistema. Dada a ausência de mecanismos de autenticação e de um servidor centralizado, todas as funcionalidades expostas operam estritamente do lado do cliente. Os casos de utilização essenciais são os seguintes:

- **Inicializar e Calibrar Deteção**: Confirmar a deteção da mão antes de iniciar qualquer avaliação.
- **Selecionar Modo de Utilização**: Escolher entre Avaliação Estática Livre, Aprendizagem ou Avaliação Dinâmica.
- **Selecionar Gesto a Treinar**: No modo de Aprendizagem, indicar qual o gesto alvo.
- **Executar Avaliação Estática**: Posicionar a mão perante a câmara e receber classificação e feedback sobre um gesto estático.
- **Executar Avaliação Dinâmica**: Realizar um gesto com movimento e receber classificação e feedback através de comparação temporal.
- **Configurar Feedback Visual**: Ativar ou desativar zonas corporais e as guias exclusivas do modo estático (esqueleto de referência e bússola de inclinação).
- **Exportar Molde Local**: Captar a execução de um gesto e transferir o respetivo ficheiro JSON para o armazenamento local do computador (funcionalidade de suporte que não altera a base de dados pública do sistema).

A.4 Matriz de Prioridades dos Casos de Utilização

De modo a estabelecer uma relação de ordem e garantir que os casos de utilização mais críticos sejam detalhados e implementados nos primeiros ciclos do projeto, procedeu-se ao seu escalonamento através de uma Matriz de Prioridades.

A prioridade é estabelecida avaliando o contributo de cada caso para o sistema, com base em seis características fundamentais. A cada característica foi atribuído um peso, variando entre 1 (não afeta/peso baixo), 2 (peso médio) e 3 (peso alto):

- **C1 - Tecnologias novas ou arriscadas (Peso 3):** Envolve esforço de investigação computacional (ex: *MediaPipe*, DTW com banda Sakoe-Chiba).

- **C2 - Alta complexidade ou tempo de resposta crítico (Peso 3):** Exige processamento em tempo real contínuo e com requisitos estritos de baixa latência na interface.
- **C3 - Persistência e Estruturas de Dados (Peso 1):** Exige gestão de estruturas de dados ou persistência local (ex: armazenamento, serialização e análise dos ficheiros JSON de referência).
- **C4 - Conhecimento específico do domínio (Peso 2):** Exige a integração e validação de regras linguísticas, fonológicas e espaciais rigorosas da LGP.
- **C5 - Funcionalidade Nuclear (Peso 3):** Representa uma funcionalidade sem a qual o sistema perde o seu propósito principal (validação da prova de conceito).
- **C6 - Valor Pedagógico Acrescentado (Peso 2):** Mede o impacto direto e a utilidade prática que a funcionalidade traz à aprendizagem e correção do utilizador.

Para cada Caso de Utilização identificado na secção anterior, foram atribuídos pontos de 1 (contributo mínimo) a 5 (contributo máximo) em cada característica. A pontuação final resulta da soma do produto dos pontos pelos respetivos pesos ($\sum \text{Ponto} \times \text{Peso}$), como se apresenta na Tabela A.1.

Tabela A.1: Matriz de Prioridades dos Casos de Utilização.

Caso de Utilização	**C1 (P3)**	**C2 (P3)**	**C3 (P1)**	**C4 (P2)**	**C5 (P3)**	**C6 (P2)**	**Total**
Executar Avaliação Dinâmica	5	5	2	5	5	5	**67**
Executar Avaliação Estática	5	4	2	5	5	5	**64**
Inicializar e Calibrar Deteção	3	4	1	2	5	2	**45**
Selecionar Gesto a Treinar	2	2	2	3	4	4	**40**
Configurar Feedback Visual	1	2	1	1	2	3	**24**
Selecionar Modo de Utilização	1	2	1	1	3	1	**23**
Exportar Molde Local	2	1	3	1	1	2	**21**

De acordo com os princípios de desenvolvimento iterativo, as decisões para o primeiro ciclo de implementação decorreram da interpretação conjunta desta matriz. Embora o caso **"Executar Avaliação Dinâmica"** tenha atingido a pontuação máxima (67 pontos), refletindo o facto de a LGP

ser uma língua assente na articulação do movimento no espaço, detendo assim o maior valor pedagógico e nuclear, a sua implementação arquitetural depende intimamente da resolução espacial do fotograma isolado. Por conseguinte, os casos **"Executar Avaliação Estática"** (64 pontos) e **"Inicializar e Calibrar Deteção"** (45 pontos) foram definidos como os pontos de entrada imperativos, servindo de alicerce técnico obrigatório para o primeiro ciclo de desenvolvimento, permitindo consolidar o *pipeline* antes da posterior avaliação temporal.

Apêndice B

Excertos de Código-Fonte

Este apêndice compila os principais excertos de código *JavaScript* que sustentam a arquitetura e os motores de avaliação do LGP-Eval, referenciados ao longo do Capítulo de Implementação do Modelo.

Inicialização do Sistema

Código 1: Inicializacao do motor Holistic via WebAssembly.

```
const holistic = new Holistic({
    locateFile: (file) => {
        return `https://cdn.jsdelivr.net/npm/@mediapipe
            /holistic/${file}`;
    }
});
holistic.setOptions({
    modelComplexity: 1,
    smoothLandmarks: true,
    enableSegmentation: false,
    refineFaceLandmarks: false,
    minDetectionConfidence: 0.76,
    minTrackingConfidence: 0.8
});
```

Máquina de Estados e Segmentação

Código 2: Transicao para o estado DEBOUNCE dentro de processarMaoUnificada.

```
if (estadoSegmentacao[labelMao] === 'GRAVANDO') {
    estadoSegmentacao[labelMao] = 'DEBOUNCE';
    if (!timerDebounce[labelMao]) {
        timerDebounce[labelMao] = setTimeout(() => {
            dispararAvaliacaoDTW(labelMao);
        }, DEBOUNCE_MS);
    }
}
```

Normalização Geométrica

Código 3: Correcao de proporcao, translacao e escala em normalizarLandmarks.

```
function normalizarLandmarks(landmarks, larguraCamara,
   alturaCamara) {
    const proporcaoCamara = larguraCamara /
       alturaCamara;
    const pontosCorrigidos = landmarks.map(ponto => ({
        x: ponto.x * proporcaoCamara,
        y: ponto.y,
        z: ponto.z
    }));
    const pulso = pontosCorrigidos[0];
    const baseMedio = pontosCorrigidos[9];
    const tamanhoPalma = Math.sqrt(
        Math.pow(baseMedio.x - pulso.x, 2) +
        Math.pow(baseMedio.y - pulso.y, 2)
    );
    return pontosCorrigidos.map(ponto => ({
        x: (ponto.x - pulso.x) / tamanhoPalma,
        y: (ponto.y - pulso.y) / tamanhoPalma,
        z: (ponto.z - pulso.z) / tamanhoPalma
    }));
}
```

Avaliação Dinâmica (Motor DTW)

Código 4: Matriz de custos DTW restringida pela Banda de Sakoe-Chiba.

```
function calcularDTW(seqUtilizador, seqMolde, w = 10) {
    const N = seqUtilizador.length;
    const M = seqMolde.length;
    const banda = Math.max(w, Math.abs(N - M));
    const dtw = Array(N + 1).fill(null).map(() => Array
        (M + 1).fill(Infinity));
    dtw[0][0] = 0;
    for (let i = 1; i <= N; i++) {
        const jMin = Math.max(1, i - banda);
        const jMax = Math.min(M, i + banda);
        for (let j = jMin; j <= jMax; j++) {
            const custo = calcularCustoEntreDuasFrames(
                seqUtilizador[i - 1], seqMolde[j - 1]
            );
            dtw[i][j] = custo + Math.min(
                dtw[i - 1][j], dtw[i][j - 1], dtw[i -
                    1][j - 1]
            );
        }
    }
    return dtw[N][M] / (N + M);
}
```

Código 5: Composicao do custo local (erro geometrico, zona e distancias faciais).

```
function calcularCustoEntreDuasFrames(frameUtilizador,
    frameMolde) {
    // 1. Erro geometrico medio dos 21 pontos da mao
    let erroGeometrico = 0;
    for (let i = 0; i < 21; i++) {
        const dx = frameUtilizador.mao[i].x -
            frameMolde.mao[i].x;
        const dy = frameUtilizador.mao[i].y -
            frameMolde.mao[i].y;
        erroGeometrico += Math.sqrt(dx * dx + dy * dy);
    }
    erroGeometrico /= 21;
```

```
    // 2. Penalizacao por zona corporal incorreta
    let penalizacaoZona = 0;
    if (zonaUtilizador !== zonaMolde) { penalizacaoZona
        = 1.20; }

    // 3. Erro de distancia facial relativa
    let erroFacial = (somaDiferencasDistRelFace / 5) *
       1.5;

    return erroGeometrico + penalizacaoZona +
       erroFacial;
}
```

Código 6: Calculo das 5 distancias relativas do pulso a face.

```
function calcularDistRelFace(pulsoX, pulsoY,
   poseLandmarks, labelMao) {
    const dists = POSE_FACE_INDICES.map(idx => {
        const pt = poseLandmarks[idx];
        const dx = pulsoX - pt.x;
        const dy = pulsoY - pt.y;
        return Math.sqrt(dx * dx + dy * dy);
    });
    if (labelMao === 'Left') {
        [dists[1], dists[2]] = [dists[2], dists[1]];
        [dists[3], dists[4]] = [dists[4], dists[3]];
    }
    return dists;
}
```

Interface e Feedback Pedagógico

Código 7: Mapeamento do erro numerico para feedback visual em atualizar-FeedbackHTML.

```
function atualizarFeedbackHTML(erroDecimal, angAtual,
   angIdeal, mensagemAlerta, reconhecido) {
    const erroMaximo = 0.40; const erroMinimo = 0.10;
    let progresso = (erroMaximo - erroDecimal) / (
       erroMaximo - erroMinimo);
```

```
progresso = Math.max(0, Math.min(1, progresso));

let corBarra = "#FF3333"; let textoFeedback = "
    LONGE...";
if (erroDecimal <= 0.10) { corBarra = "#00FF00";
    textoFeedback = "FEITO!"; }
else if (erroDecimal <= 0.25) { corBarra = "#FFA500
    "; textoFeedback = "QUASE LA!"; }

barra.style.width = (progresso * 100) + "%";
barra.style.backgroundColor = corBarra;}
```

Apêndice C

Gestão de Versões e Controlo de Código

O código-fonte do LGP-Eval foi versionado com **Git**, num repositório remoto centralizado no **GitHub**, partilhado pelos dois autores do projeto. O repositório guardou tanto o código-fonte da aplicação (`.html`, `.css`, `.js`) como os artefactos de dados gerados pelo próprio sistema, nomeadamente os moldes de referência em formato JSON (Secção 4.2).

C.1 Ramos e Junções (*Branches* e *Merges*)

O desenvolvimento decorreu sobre um único ramo principal, o `main`, sem recurso a ramos de funcionalidade (*feature branches*) persistentes. Dada a equipa reduzida (dois autores) e a forte interdependência entre os módulos do sistema (motor estático, motor dinâmico e interface partilham o mesmo estado global), optou-se por um modelo de integração contínua diretamente sobre o `main`, com cada autor a sincronizar o seu trabalho local com o ramo remoto `origin/main` através de `git pull` e `git push` frequentes.

Ainda assim, o histórico regista *commits* de junção (*merge*) explícitos, resultantes da reconciliação automática de trabalho desenvolvido em paralelo pelos dois autores antes da sincronização com o remoto. O mais relevante ocorreu a 15 de abril de 2026 (`Merge: Fusão da telemetria com a interface de debug e correção do bug do gestoAlvo`), integrando o painel de telemetria de diagnóstico com a interface de *debug*, dois módulos desenvolvidos em simultâneo. Dois outros *merges* de `origin/main`, a 15 e

16 de julho de 2026, reconciliaram a introdução dos moldes do alfabeto com correções de interface do modo de avaliação.

C.2 Arquitetura de Sincronização

A interligação entre o trabalho dos dois autores assentou na arquitetura padrão do Git: cada autor manteve uma cópia local do repositório, sincronizada com o repositório remoto único no GitHub via HTTPS, sem infraestrutura de integração contínua adicional. Esta simplicidade é coerente com a arquitetura do próprio LGP-Eval: por não haver *backend* nem processo de *build* (Secção 4.1), o repositório corresponde diretamente ao artefacto final da aplicação, e o versionamento textual do Git permitiu ainda rastrear, ficheiro a ficheiro, a evolução da base de dados de gestos em JSON, dispensando qualquer base de dados dedicada.

Bibliografia

[Aloysius e Geetha, 2020] Aloysius, N. e Geetha, M. (2020). Understanding vision-based continuous sign language recognition. *Multimedia Tools and Applications*, 79:22589–22609.

[Aran et al., 2009] Aran, O., Ari, I., Akarun, L., Sankur, B., Benoit, A., Caplier, A., Campr, P., Carrillo, A. H., e Fanard, F.-X. (2009). Signtutor: An interactive system for sign language tutoring. *IEEE MultiMedia*, 16(1):80–93.

[Arici et al., 2014] Arici, T., Celebi, S., Aydin, A. S., e Temiz, T. T. (2014). Robust gesture recognition using feature pre-processing and weighted dynamic time warping. *Multimedia Tools and Applications*, 71(3):1565–1585.

[Baihan et al., 2024] Baihan, A., Alutaibi, A. I., Alshehri, M., e Sharma, S. K. (2024). Sign language recognition using modified deep learning network and hybrid optimization: a hybrid optimizer (ho) based optimized cnnsa-lstm approach. *Scientific Reports*, 14(1):26111.

[Cheok et al., 2019] Cheok, M. J., Omar, Z., e Jaward, M. H. (2019). A review of hand gesture and sign language recognition techniques. *International Journal of Machine Learning and Cybernetics*, 10(1):131–153.

[Duolingo, Inc., 2026] Duolingo, Inc. (2026). Duolingo – learn languages for free. `https://www.duolingo.com`. Consultado em Julho de 2026.

[Hand Talk, 2026] Hand Talk (2026). Hand talk app – automatic sign language translator. `https://www.handtalk.me/en/`. Consultado em Julho de 2026.

[Levy, 1997] Levy, M. (1997). *Computer-Assisted Language Learning: Context and Conceptualization*. Oxford University Press.

[Lugaresi e et al., 2019] Lugaresi, C. e et al. (2019). MediaPipe: A framework for perceiving and processing reality. In *Third Workshop on Computer Vision for AR/VR at IEEE CVPR*.

[Ministério da Administração Interna, 2026] Ministério da Administração Interna (2026). MAI112 - Aplicação Mobile para Cidadãos Surdos. `https://www.sg.mai.gov.pt/tecnologias/112pt/appmobilepcidadaossurdos/Paginas/default.aspx`. Acedido em: 21 de Julho de 2026.

[MobiReactor, 2026] MobiReactor (2026). Asl sign language – pocket sign. `https://www.pocketsign.com`. Consultado em Julho de 2026.

[Plouffe e Cretu, 2016] Plouffe, G. e Cretu, A.-M. (2016). Static and dynamic hand gesture recognition in depth data using dynamic time warping. *IEEE Transactions on Instrumentation and Measurement*, 65(2):305–316.

[Sakoe e Chiba, 1978] Sakoe, H. e Chiba, S. (1978). Dynamic programming algorithm optimization for spoken word recognition. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 26(1):43–49.